数值线性代数——第 5 讲

Lloyd N. Trefethen、David Bau III

第 5 讲　SVD 的更多内容

原书页 32–38；目标 PDF 页 47–54。继续讨论奇异值分解，并重点说明它与矩阵低秩近似、2-范数和弗罗贝尼乌斯范数之间的联系。

换基

SVD 使我们能够说：只要选取合适的定义域和值域基，每一个矩阵都可以看成对角矩阵。

设 $A = U\Sigma V^*$ 是完整 SVD。任意 $b \in \mathbb{C}^m$ 都可以在 U 的列（左奇异向量）构成的基下展开，任意 $x \in \mathbb{C}^n$ 都可以在 V 的列（右奇异向量）构成的基下展开。相应的坐标向量是

$$b' = U^* b, \qquad x' = V^* x.$$

由 (4.3)，关系 $b = Ax$ 等价于

$$b = Ax \quad \Longleftrightarrow \quad U^* b = U^* A x = U^* U \Sigma V^* x \quad \Longleftrightarrow \quad b' = \Sigma x'.$$

因此，当值域用 U 的列向量表示、定义域用 V 的列向量表示时，A 就被化成了对角矩阵 Σ。

SVD 与特征值分解

用新基把矩阵对角化的思想，也贯穿于特征值的研究。若方阵 A 非缺陷（具有一组线性无关的特征向量），则它可以写成

$$A = X \Lambda X^{-1}, \tag{5.1}$$

其中 $X \in \mathbb{C}^{m \times m}$ 的列是 A 的线性无关特征向量，Λ 是以 A 的特征值为对角元的对角矩阵。若 $b = Ax$，定义

$$b' = X^{-1} b, \qquad x' = X^{-1} x,$$

则同样有 $b' = \Lambda x'$。特征值将在第 24 讲系统讨论。

SVD 与特征值分解有几个根本差别：

1. SVD 使用两组基——左奇异向量和右奇异向量；特征值分解只使用一组基，即特征向量；
2. SVD 使用标准正交基，而特征值分解使用的基一般并不正交；
3. 并非所有矩阵（甚至并非所有方阵）都有特征值分解，但所有矩阵（包括矩形矩阵）都有奇异值分解。

在应用中，特征值通常与 A 的迭代形式有关，例如矩阵幂 A^k 或矩阵指数 e^A；而奇异向量通常与 A 本身或 A^{-1} 的行为有关。

用 SVD 描述矩阵性质

以下设 A 是 $m \times n$ 矩阵，$p = \min(m, n)$，$r \leq p$ 是 A 的非零奇异值个数。记

$$\text{span}(x, y, \dots, z)$$

为由向量 $x, y, \dots, z$ 张成的空间。

定理 5.1

$$\text{rank}(A) = r,$$

即 A 的秩等于非零奇异值的个数。

证明。 对角矩阵的秩等于其非零对角元的个数。在 $A = U\Sigma V^*$ 中，U, V 都满秩，因此

$$\text{rank}(A) = \text{rank}(\Sigma) = r.$$

证毕。

定理 5.2

$$\text{range}(A) = \text{span}(u_1, \dots, u_r), \qquad \text{null}(A) = \text{span}(v_{r+1}, \dots, v_n).$$

证明。 Σ 的值域是 $\text{span}(e_1, \dots, e_r) \subset \mathbb{C}^m$，零空间是 $\text{span}(e_{r+1}, \dots, e_n) \subset \mathbb{C}^n$。左乘 U、右乘 V^* 只是在相应的标准正交基之间换基，故结论成立。证毕。

定理 5.3

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \left(\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_p^2\right)^{1/2}.$$

证明。 在定理 4.1 的存在性证明中已经得到

$$\|A\|_2 = \|\Sigma\|_2 = \max_i \sigma_i = \sigma_1,$$

这里使用了酉乘法下 2-范数的不变性。由同样的不变性和 (3.16),

$$\|A\|_F = \|\Sigma\|_F = \left(\sigma_1^2 + \cdots + \sigma_p^2\right)^{1/2}.$$

证毕。

定理 5.4

A 的非零奇异值，是 A^*A 或 AA^* 的非零特征值的平方根；这两个矩阵具有相同的非零特征值。

证明。 由 SVD,

$$A^*A = (U\Sigma V^*)^*(U\Sigma V^*) = V\Sigma^* U^* U\Sigma V^* = V(\Sigma^*\Sigma)V^*.$$

所以 A^*A 与 $\Sigma^*\Sigma$ 酉相似，具有相同的 n 个特征值。后者的对角元为

$$\sigma_1^2, \dots, \sigma_p^2$$

以及（当 $n > p$ 时）若干个额外的零。对 AA^* 做完全类似的计算即可得到同样的结论。证毕。

定理 5.5

若 $A = A^*$，则 A 的奇异值等于其特征值的绝对值。

证明。 厄米矩阵有一组完整的正交特征向量，且所有特征值都为实数。因此可写成

$$A = Q\Lambda Q^*,$$

其中 Q 酉，Λ 为实对角矩阵。令 $|\Lambda|$ 的对角元为 $|\lambda_i|$，令 $\operatorname{sign}(\Lambda)$ 的对角元为 $\operatorname{sign}(\lambda_i)$，则

$$A = Q\,|\Lambda|\,\operatorname{sign}(\Lambda)\,Q^*.$$

$\operatorname{sign}(\Lambda)Q^*$ 仍为酉矩阵，所以这已经是一个 SVD，只是奇异值还未必按非增顺序排列。必要时插入置换矩阵重新排序即可。故奇异值为 $|\lambda_i|$。证毕。

定理 5.6

若 $A \in \mathbb{C}^{m\times m}$，则

$$|\det(A)| = \prod_{i=1}^{m} \sigma_i.$$

证明。 方阵乘积的行列式等于各因子行列式之积。酉矩阵 U 满足 $U^*U = I$，所以 $|\det U| = 1$；同理 $|\det V^*| = 1$。于是

$$|\det(A)| = |\det(U\Sigma V^*)| = |\det(U)|\,|\det(\Sigma)|\,|\det(V^*)| = |\det(\Sigma)| = \prod_{i=1}^{m} \sigma_i.$$

证毕。

低秩近似

理解 SVD 的另一条路径，是研究如何把矩阵 A 表示成若干秩一矩阵之和。

定理 5.7

A 可以写成 r 个秩一矩阵之和：

$$A = \sum_{j=1}^{r} \sigma_j u_j v_j^*. \tag{5.3}$$

证明。 把 Σ 写成 r 个矩阵 Σ_j 之和，其中 Σ_j 只有第 j 个对角元为 σ_j，其余元素为零。代入 $A = U\Sigma V^*$ 即得 (5.3)。证毕。

把 $m \times n$ 矩阵写成秩一矩阵之和有很多方式：可以按行相加、按列相加，也可以把每个元素分别写成一个秩一矩阵。高斯消元还会把 A 写成一系列秩一矩阵之和，其中后一个矩阵的前几行和前几列逐渐为零。

不过，(5.3) 有一个更深的性质：它的第 ν 个部分和，在 2-范数或弗罗贝尼乌斯范数意义下，尽可能多地保留了 A 的“能量”。把这个说法写成低秩最佳逼近定理，就是下面的结果。

定理 5.8

对任意 $0 \le \nu \le r$，定义

$$A_\nu = \sum_{j=1}^{\nu} \sigma_j u_j v_j^*. \tag{5.4}$$

当 $\nu = p = \min(m,n)$ 时，约定 $\sigma_{\nu+1} = 0$。则

$$\|A - A_\nu\|_2 = \inf_{\substack{B \in \mathbb{C}^{m\times n} \\ \operatorname{rank}(B) \le \nu}} \|A - B\|_2 = \sigma_{\nu+1}.$$

证明。 假设存在某个 $\operatorname{rank}(B) \le \nu$ 的矩阵，使

$$\|A - B\|_2 < \|A - A_\nu\|_2 = \sigma_{\nu+1}.$$

由于 B 的秩至多为 ν，存在一个维数为 $n - \nu$ 的子空间 $W \subset \mathbb{C}^n$，使得对所有 $w \in W$，都有 $Bw = 0$。因此

$$Aw = (A - B)w,$$

并且

$$\|Aw\|_2 = \|(A - B)w\|_2 \le \|A - B\|_2 \|w\|_2 < \sigma_{\nu+1}\|w\|_2.$$

另一方面，由 A 的前 $\nu + 1$ 个右奇异向量张成的子空间维数为 $\nu + 1$，其中每个向量 w 都满足

$$\|Aw\|_2 \ge \sigma_{\nu+1}\|w\|_2.$$

这两个子空间的维数之和为 $n + 1$，因此必有非零向量同时属于它们，矛盾。故不存在这样的 B，而 A_ν 已经达到该下界。证毕。

定理 5.8 的几何含义是：用线段逼近超椭球时，最佳线段应取最长轴；用二维椭圆逼近时，应取由最长轴和第二长轴张成的椭圆；依此类推，每一步都加入尚未选取的最长轴。取完 r 个轴后，就完全恢复了 A 的作用。这一思想应用于图像压缩（见习题 9.3）、泛函分析等许多领域。

弗罗贝尼乌斯范数也有完全对应的结论。

定理 5.9

对任意 $0 \le \nu \le r$，由 (5.4) 定义的 A_ν 满足

$$\|A - A_\nu\|_F = \inf_{\substack{B \in \mathbb{C}^{m\times n} \\ \operatorname{rank}(B) \le \nu}} \|A - B\|_F = \left(\sigma_{\nu+1}^2 + \cdots + \sigma_p^2\right)^{1/2}.$$

SVD 的计算

前两讲研究了 SVD 的性质，但还没有说明如何计算它。事实上，SVD 的计算是一个很有趣的主题；最好的方法是特征值算法的变体，本书将在第 31 讲讨论。

一旦能够计算 SVD，它就可以作为处理各种问题的工具。前面的大多数定理都有直接的计算后果：

- 确定矩阵秩的最佳方法，是统计大于合理容差的奇异值个数（定理 5.1）；
- 求值域或零空间的标准正交基，最准确的方法是使用定理 5.2（QR 分解提供更快但不总是同样准确的替代算法）；
- 定理 5.3 给出了计算 $\|A\|_2$ 的标准方法；
- 定理 5.8 和 5.9 给出了分别关于 2-范数和弗罗贝尼乌斯范数的低秩逼近标准；
- SVD 还是稳健最小二乘拟合、子空间交、正则化以及许多其他问题的算法组成部分。

习题

5.1 例 3.1 中考虑了矩阵 (3.7)，并指出它的 2-范数约为 2.9208。利用 SVD，在纸上求出这个矩阵的 $\sigma_{\min}(A)$ 和 $\sigma_{\max}(A)$ 的精确值。

5.2 利用 SVD 证明：$\mathbb{C}^{m\times n}$ 中的任意矩阵都是一列满秩矩阵的极限。换言之，证明满秩矩阵集合是 $\mathbb{C}^{m\times n}$ 的稠密子集。证明中使用 2-范数。（使用哪一种范数并不重要，因为有限维空间上的所有范数都等价。）

5.3 考虑矩阵

$$A = \begin{bmatrix} -2 & 11 \\ -10 & 5 \end{bmatrix}.$$

(a) 手算一个实 SVD $A = U\Sigma V^{\mathsf{T}}$。SVD 并不唯一，请找出 U, V 中负号最少的那个版本。

(b) 列出 A 的奇异值、左奇异向量和右奇异向量。仔细画出 $\mathbb{R}^2$ 单位球及其在 A 下的像，并画出奇异向量，同时标出各顶点坐标。

(c) 求 A 的 1-范数、2-范数、∞-范数和弗罗贝尼乌斯范数。

(d) 不要直接求逆，利用 SVD 求 A^{-1}。

(e) 求 A 的特征值 λ_1, λ_2。

(f) 验证

$$\det A = \lambda_1\lambda_2, \qquad |\det A| = \sigma_1\sigma_2.$$

(g) A 把 $\mathbb{R}^2$ 的单位球映射到一个椭圆。求这个椭圆的面积。

5.4 设 $A \in \mathbb{C}^{m\times m}$ 有 SVD $A = U\Sigma V^*$。对 Hermitian 矩阵

$$H = \begin{bmatrix} 0 & A^* \\ A & 0 \end{bmatrix} \in \mathbb{C}^{2m\times 2m},$$

求其特征值分解 (5.1)。