数值线性代数　第 11 讲：最小二乘问题

Lloyd N. Trefethen、David Bau III　中文阅读版

自高斯和勒让德在 1800 年前后发明最小二乘法以来，最小二乘数据拟合一直是不可或缺的工具，并且影响遍及数学科学的许多领域. 用线性代数的语言说，本讲要处理的是超定方程组 $Ax = b$：矩阵是长方形的，行数多于列数. 最小二乘的思想，是通过最小化残差 $b - Ax$ 的 2-范数来“求解”这样的系统.

问题

考虑一个含有 n 个未知数、但有 $m > n$ 个方程的线性方程组. 我们希望找到满足 $Ax = b$ 的向量 $x \in \mathbb{C}^n$，其中

$$A \in \mathbb{C}^{m\times n}, \qquad b \in \mathbb{C}^m.$$

一般而言，这样的方程组没有解. 只有当 $b \in \text{range}(A)$ 时才存在合适的 x；而 b 是 m 维向量，$\text{range}(A)$ 的维数至多为 n，所以这只会对特殊的 b 发生. 当 $m > n$ 时，这样的长方形方程组称为**超定**方程组.

把

$$r = b - Ax \in \mathbb{C}^m \tag{11.1}$$

称为**残差**. 通过选择合适的 x，残差通常可以变得很小，但一般无法严格变成零.

如果一个没有解的问题仍要谈“求解”，这意味着什么？对超定方程组，一个自然的答案是：既然不能让残差 r 等于零，就让它尽可能小. 要衡量“小”，需要先选择范数. 如果选择 2-范数，问题就成为：

$$\begin{aligned} &\text{给定} A \in \mathbb{C}^{m\times n}, \quad m \ge n, \quad b \in \mathbb{C}^m, \\ &\text{寻找} x \in \mathbb{C}^n, \quad \text{使} \|b - Ax\|_2 \text{ 最小}. \end{aligned} \tag{11.2}$$

这就是一般的（线性）最小二乘问题. 选择 2-范数可以由几何和统计方面的多种理由来支持；正如后面将看到的，它还会导出简单的算法，根本原因在于：二次函数的导数是线性的，而求极小值必须令导数为零.

2-范数对应欧氏距离，因此式 (11.2) 有一个直观的几何解释：寻找 $x \in \mathbb{C}^n$，使得 $Ax \in \mathbb{C}^m$ 是 $\text{range}(A)$ 中距离 b 最近的点.

例：多项式数据拟合

下面比较两种做法：多项式插值会导出方阵方程组；最小二乘多项式数据拟合则使用长方形方程组.

例 11.1：多项式插值

设给定 m 个互异的点 $x_1, \ldots, x_m \in \mathbb{C}$，以及这些点上的数据 $y_1, \ldots, y_m \in \mathbb{C}$. 存在唯一的多项式插值函数，即次数至多为 $m-1$ 的多项式

$$p(x) = c_0 + c_1 x + \cdots + c_{m-1} x^{m-1}, \tag{11.3}$$

满足每个 x_i 都有 $p(x_i) = y_i$. 数据 $\{x_i\}, \{y_i\}$ 与系数 $\{c_i\}$ 的关系，可由例 1.1 中已经见过的方形 Vandermonde 系统表示：

$$\begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{m-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{m-1} \\ 1 & x_3 & x_3^2 & \cdots & x_3^{m-1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^{m-1} \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \\ \vdots \\ c_{m-1} \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_m \end{bmatrix}. \tag{11.4}$$

只要点 $\{x_i\}$ 互异，这个方程组就保证非奇异，因此可以求出给定数据对应的系数（见习题 37.3）.

图 1 给出了一个多项式插值的例子：有 11 个数据点，它们构成一个离散的方波，用叉号表示；曲线 $p(x)$ 必须经过所有这些点. 但这个拟合并不令人满意. 在区间两端，$p(x)$ 出现很大的振荡，这显然是插值过程产生的伪影，而不是数据的合理反映.

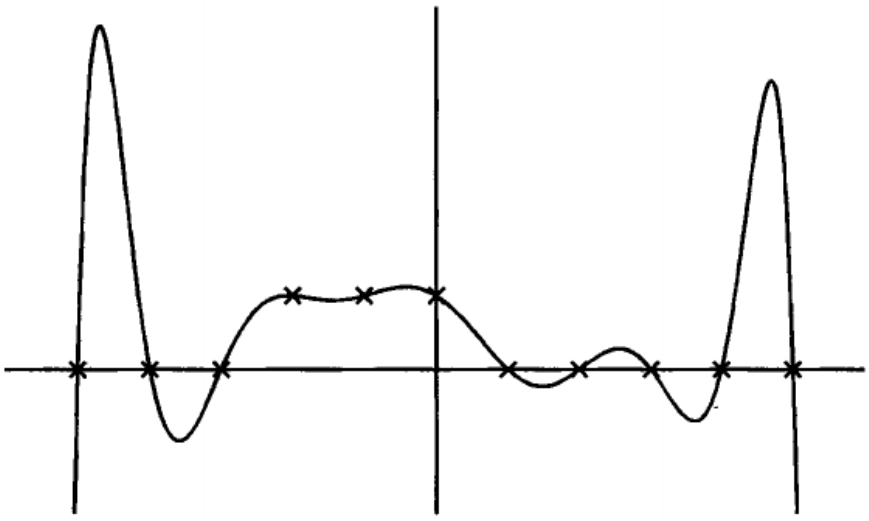


图 1: 11 个数据点的 10 次多项式插值. 图中不标出坐标轴刻度，因为刻度不会影响所要表达的形状.

这种不理想的行为是多项式插值的典型特征. 它产生的拟合往往很差；使用更多数据时，情况还可能变得更糟. 即使拟合看起来不错，插值过程也可能是病态的，也就是对数据扰动敏感（下一讲会讨论）. 为了避免这些问题，可以在区间 $[-1,1]$ 中使用非均匀的插值点，例如 Chebyshev 点. 但是在实际应用中，我们未必能随意选择插值点.

例 11.2：多项式最小二乘拟合

不改变数据点，只降低多项式的次数，通常就能得到更好的结果. 仍给定 $x_1,\dots,x_m$ 和 $y_1,\dots,y_m$，现在考虑某个 $n<m$ 的 $n-1$ 次多项式

$$p(x)=c_0+c_1x+\cdots+c_{n-1}x^{n-1}. \tag{11.5}$$

如果它能使数据偏差平方和

$$\sum_{i=1}^{m}|p(x_i)-y_i|^2 \tag{11.6}$$

最小，那么这个多项式就是数据的最小二乘拟合.

这个平方和等于长方形 Vandermonde 系统残差 2-范数的平方：

$$\begin{bmatrix}1 & x_1 & \cdots & x_1^{n-1}\\ 1 & x_2 & \cdots & x_2^{n-1}\\ 1 & x_3 & \cdots & x_3^{n-1}\\ \vdots & \vdots & & \vdots\\ 1 & x_m & \cdots & x_m^{n-1}\end{bmatrix}\begin{bmatrix}c_0\\ c_1\\ \vdots\\ c_{n-1}\end{bmatrix}\approx\begin{bmatrix}y_1\\ y_2\\ y_3\\ \vdots\\ y_m\end{bmatrix}. \tag{11.7}$$

图 2 展示了把上一个例子的 11 个数据点用 7 次多项式拟合时的结果. 新的多项式不再插值通过每个数据点，但例 11.1 的多项式更好地捕捉了数据的整体趋势. 虽然图中看不出来，它对扰动也更不敏感.

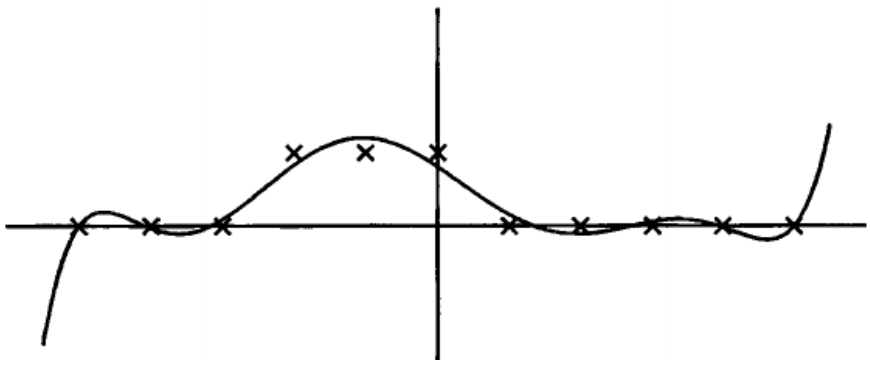


图 2: 同一组 11 个数据点的 7 次多项式最小二乘拟合.

正交投影与正规方程

图 3 说明了式 (11.2) 的几何含义. 我们的目标是在 range(A) 中寻找距离 b 最近的点 Ax，使残差 $r = b - Ax$ 的范数最小. 从几何上看，只要

$$Ax = Pb,$$

其中 $P \in \mathbb{C}^{m\times m}$ 是把 $\mathbb{C}^m$ 映到 range(A) 的正交投影，就能达到这个目标. 换言之，残差 $r = b - Ax$ 必须与 range(A) 正交. 这可以表述为下面的定理.

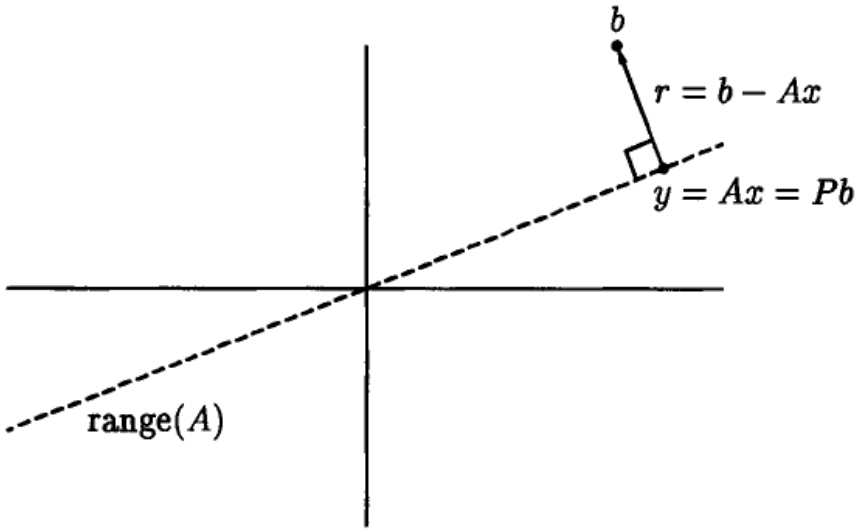


图 3: 用正交投影表述最小二乘问题 (11.2).

定理 11.1. 设 $A \in \mathbb{C}^{m\times n}$ （$m \geq n$）和 $b \in \mathbb{C}^m$ 给定. 向量 $x \in \mathbb{C}^n$ 最小化残差范数

$$\|r\|_2 = \|b - Ax\|_2,$$

从而解决最小二乘问题 (11.2)，当且仅当 $r \perp$ range(A)，也就是

$$A^*r = 0. \tag{11.8}$$

等价地，

$$A^*Ax = A^*b, \tag{11.9}$$

或者

$$Pb = Ax, \tag{11.10}$$

其中 $P \in \mathbb{C}^{m\times m}$ 是到 range(A) 上的正交投影. 式 (11.9) 所对应的 $n \times n$ 方程组称为**正规方程**. 它非奇异，当且仅当 A 满列秩. 因此，最小二乘解唯一，当且仅当 A 满列秩.

证明. 式 (11.8) 与式 (11.10) 的等价性来自第 6 讲讨论的正交投影性质；式 (11.8) 与式 (11.9) 的等价性来自残差 r 的定义.

要说明 $y = Pb$ 是 $\mathrm{range}(A)$ 中唯一的最小化 $\|b - y\|_2$ 的点，设 $z \neq y$ 是 $\mathrm{range}(A)$ 中的另一个点. 由于 $z - y$ 与 $b - y$ 正交，勾股定理（习题 2.2）给出

$$\|b - z\|_2^2 = \|b - y\|_2^2 + \|y - z\|_2^2 > \|b - y\|_2^2,$$

这正是所需结论.

最后，如果 A^*A 奇异，那么存在非零 x 使 $A^*Ax = 0$. 左乘 x^* 得

$$x^*A^*Ax = \|Ax\|_2^2 = 0,$$

因此 $Ax = 0$，说明 A 秩亏. 反过来，如果 A 秩亏，那么存在非零 x 使 $Ax = 0$，于是也有 $A^*Ax = 0$，所以 A^*A 奇异. 结合式 (11.9)，就得到关于 A^*A 非奇异性与最小二乘解唯一性的结论. □

伪逆

刚才已经看到，如果 A 满列秩，那么最小二乘问题 (11.2) 的解唯一，并且

$$x = (A^*A)^{-1}A^*b.$$

矩阵

$$A^+ = (A^*A)^{-1}A^* \in \mathbb{C}^{n\times m} \tag{11.11}$$

称为 A 的**伪逆**. 它把 $b \in \mathbb{C}^m$ 映射为 $x \in \mathbb{C}^n$，这也解释了为什么它的尺寸是 $n \times m$，即列数多于行数.

满列秩线性最小二乘问题 (11.2) 可以概括为：要计算下面两个向量中的一个或两个：

$$x = A^+b, \qquad y = Pb. \tag{11.12}$$

其中 A^+ 是 A 的伪逆，P 是到 $\mathrm{range}(A)$ 上的正交投影. 下面介绍计算它们的三种主要算法.

正规方程

求解最小二乘问题的经典方法，是直接求解正规方程 (11.9). 如果 A 满列秩，这是一组 $n \times n$ 的 Hermitian 正定方程. 求解这类系统的标准方法是 Cholesky 分解，第 23 讲将讨论它. 该方法构造

$$A^*A = R^*R,$$

其中 R 是上三角矩阵，从而把式 (11.9) 化为

$$R^*Rx = A^*b. \tag{11.13}$$

算法 11.1：通过正规方程求解最小二乘问题

1. 构造矩阵 A^*A 和向量 A^*b.
2. 计算 Cholesky 分解 $A^*A = R^*R$.
3. 对 w 求解下三角方程组 $R^*w = A^*b$.
4. 对 x 求解上三角方程组 $Rx = w$.

这个计算中占主要工作量的是前两步（第 17 讲讨论第 3、4 步）. 利用对称性，计算 A^*A 只需要 mn^2 次 flop；如果 A 和 A^* 是尺寸相同但任意的矩阵，这个代价将是两倍. Cholesky 分解也利用了对称性，需要 $n^3/3$ 次 flop. 因此，用正规方程求解最小二乘问题的总运算量为

$$\text{算法 11.1 的工作量} \sim mn^2 + \frac{1}{3}n^3 \text{ flops}. \tag{11.14}$$

QR 分解

求解最小二乘问题的“现代经典”方法自 20 世纪 60 年代起广泛使用，它基于约化 QR 分解. 通过 Gram–Schmidt 正交化，或者更常用的 Householder 三角化，可以构造

$$A = \widehat{Q}\widehat{R}.$$

正交投影 P 可以写成（式 (6.6)）

$$P = \widehat{Q}\widehat{Q}^*,$$

因此

$$y = Pb = \widehat{Q}\widehat{Q}^*b. \tag{11.15}$$

由于 $y \in \text{range}(A)$，方程 $Ax = y$ 有精确解. 把 QR 分解与式 (11.15) 合并，得到

$$\widehat{Q}\widehat{R}x = \widehat{Q}\widehat{Q}^*b. \tag{11.16}$$

左乘 $\widehat{Q}^*$ 后得到

$$\widehat{R}x = \widehat{Q}^*b. \tag{11.17}$$

（再乘以 $\widehat{R}^{-1}$，就得到伪逆公式 $A^+ = \widehat{R}^{-1}\widehat{Q}^*$.）式 (11.17) 是上三角方程组；当 A 满列秩时它非奇异，可以方便地通过回代求解（第 17 讲）.

算法 11.2：通过 QR 分解求解最小二乘问题

1. 计算约化 QR 分解 $A = \widehat{Q}\widehat{R}$.
2. 计算向量 $\widehat{Q}^*b$.

3. 对 x 求解上三角方程组 $\widehat{R}x = \widehat{Q}^*b$.

注意，式 (11.17) 也可以从正规方程推出. 如果 $A^*Ax = A^*b$，那么

$$\widehat{R}^*\widehat{Q}^*\widehat{Q}\widehat{R}x = \widehat{R}^*\widehat{Q}^*b,$$

这就推出 $\widehat{R}x = \widehat{Q}^*b$.

算法 11.2 的工作量主要来自 QR 分解. 如果这一步使用 Householder 反射，那么由式 (10.9) 可得

$$\text{算法 11.2 的工作量} \sim 2mn^2 - \frac{2}{3}n^3 \text{ flops.} \tag{11.18}$$

SVD

第 31 讲将介绍计算约化奇异值分解的算法：

$$A = \widehat{U}\widehat{\Sigma}V^*.$$

这提示了另一种求解最小二乘问题的方法. 此时

$$P = \widehat{U}\widehat{U}^*,$$

从而

$$y = Pb = \widehat{U}\widehat{U}^*b. \tag{11.19}$$

式 (11.16) 和式 (11.17) 的对应形式为

$$\widehat{U}\widehat{\Sigma}V^*x = \widehat{U}\widehat{U}^*b, \tag{11.20}$$

以及

$$\widehat{\Sigma}V^*x = \widehat{U}^*b. \tag{11.21}$$

(左乘 $\widehat{V}\widehat{\Sigma}^{-1}$，得到 $A^+ = V\widehat{\Sigma}^{-1}\widehat{U}^*$.) 算法如下.

算法 11.3：通过 SVD 求解最小二乘问题

1. 计算约化 SVD $A = \widehat{U}\widehat{\Sigma}V^*$.
2. 计算向量 $\widehat{U}^*b$.
3. 对 w 求解对角方程组 $\widehat{\Sigma}w = \widehat{U}^*b$.
4. 令 $x = Vw$.

QR 分解把最小二乘问题化为三角方程组，而 SVD 把它化为对角方程组，后者当然可以直接求解. 如果 A 满列秩，对角方程组非奇异.

和前面一样，式 (11.21) 也可以由正规方程推出. 如果 $A^*Ax = A^*b$，那么

$$V\widehat{\Sigma}^*\widehat{U}^*\widehat{U}\widehat{\Sigma}V^*x = V\widehat{\Sigma}^*\widehat{U}^*b,$$

从而得到 $\widehat{\Sigma}V^*x = \widehat{U}^*b$.

算法 11.3 的运算量主要来自 SVD 的计算. 第 31 讲将看到，当 $m \gg n$ 时，其代价与 QR 分解大致相同；但当 $m \approx n$ 时，SVD 更昂贵. 一个典型估计是

$$\text{算法 11.3 的工作量} \sim 2mn^2 + 11n^3 \text{ flops}, \tag{11.22}$$

不过这个估计的适用条件和修正将在第 31 讲讨论.

算法比较

上述每种方法都有适合自己的情形. 如果唯一目标是速度，算法 11.1 可能是最好的. 但是，在舍入误差存在时，正规方程并不总是稳定；因此多年来数值分析家一直把算法 11.2 推荐为最小二乘问题的标准方法. 算法 11.2 自然而优雅，适合日常使用.

不过，如果 A 接近秩亏，算法 11.2 本身的稳定性也不够理想；在这种情况下，转向基于 SVD 的算法 11.3 有充分理由. 究竟是什么稳定性因素使某种算法在一种情况下更好、在另一种情况下却不一定更好？现在正是系统讨论这些问题的时候. 第 18、19 讲将回到最小二乘算法的研究.

习题

11.1 设 $m \times n$ 矩阵 A 具有如下形式：

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix},$$

其中 A_1 是 $n \times n$ 非奇异矩阵，A_2 是任意的 $(m-n) \times n$ 矩阵. 证明

$$\|A^+\|_2 \le \|A_1^{-1}\|_2.$$

11.2 (a) 在区间 $[1,2]$ 上用 L^2 范数衡量，函数 $f(x) = x^{-1}$ 能被函数 e^x、$\sin x$ 和 $\Gamma(x)$ 的线性组合拟合到多接近？其中 $\Gamma(x)$ 是 MATLAB 的内置 gamma 函数. 编写程序，把 $[1,2]$ 离散化并建立离散最小二乘问题，以至少两位有效数字的相对精度确定答案. 写出答案以及最优线性组合的系数估计，并画出最优近似.

(b) 重复上述过程，但把区间 $[1,2]$ 换成 $[0,1]$. 下面的事实可能有帮助：若 $g(x) = 1/\Gamma(x)$，则 $g'(0) = 1$.

11.3 取 $m = 50, n = 12$. 使用 MATLAB 的 `linspace`，定义 t 为从 0 到 1 等距网格对应的 m 维向量. 使用 MATLAB 的 `vander` 和 `fliplr`，定义 A 为这个网格上用次数 $n-1$ 多项式做最小二乘拟合所对应的 $m \times n$ 矩阵. 令 b 为在网格上计算的函数 $\cos(4t)$. 现在用以下六种方法计算并打印（精确到 16 位）最小二乘系数向量 x:

(a) 建立并求解正规方程，使用 MATLAB 的左除运算符 `\`.

(b) 使用 `mgs` 计算 QR 分解（修改后的 Gram–Schmidt，习题 8.2）.

(c) 使用 `house` 计算 QR 分解（Householder 三角化，习题 10.2）.

(d) 使用 MATLAB 的 `qr` 计算 QR 分解（同样基于 Householder 三角化）.

(e) 在 MATLAB 中使用 `x = A\b`（同样基于 QR 分解）.

(f) 使用 MATLAB 的 `svd` 计算 SVD.

11.4 以上计算会产生六组、每组十二个系数. 在每组中，用红笔标出看起来错误（受到舍入误差影响）的数字. 评论你观察到的差异. 正规方程是否表现出不稳定性? 不必解释你的观察.