数值线性代数　第 16 讲：Householder 三角化的稳定性

Lloyd N. Trefethen、David Bau III　中文阅读版

本讲将看到后向误差分析如何真正发挥作用. 首先，我们通过一个 MATLAB 实验观察 Householder 三角化具有后向稳定性这一令人惊讶的现象. 随后讨论如何把三角化步骤与其他后向稳定的步骤结合起来，从而得到求解 $Ax = b$ 的稳定算法.

实验

Householder 分解是计算 QR 分解的后向稳定算法. 可以在 IEEE 双精度算术中进行如下 MATLAB 实验，其中

$$\varepsilon_{\text{machine}} \approx 1.11 \times 10^{-16}.$$

```
R = triu(randn(50));          Set R to a 50 x 50 upper-triangular
                              matrix with normal random entries.
[Q,X] = qr(randn(50));        Set Q to a random orthogonal matrix
                              by orthogonalizing a random matrix.
A = Q*R;                      Set A to the product QR, up to round-
                              ing errors.
[Q2,R2] = qr(A);              Compute QR factorization A ~= Q2R2
                              by Householder triangularization.
```

这四行 MATLAB 的目的，是构造一个已知 QR 分解的矩阵 $A = QR$，再把它与通过 Householder 三角化计算出的 QR 分解 $A \approx Q_2R_2$ 进行比较. 实际上，由于舍入误差，计算矩阵 A 的 QR 因子并不恰好是 Q 和 R. 不过，对于这个实验，它们已经足够接近. 如果在更高精度算术中计算 $A = QR$，使 A 恰好等于 QR，下面的结果也不会有显著不同.

然而，Q_2 和 R_2 本身却远非精确:

```
norm(Q2-Q)                    How accurate is Q2?
    ans = 0.00889

norm(R2-R)/norm(R)            How accurate is R2?
    ans = 0.00071
```

这些误差很大! 我们的计算使用了 16 位精度，但最终结果只有两三位是准确的. 单次舍入误差被放大了约 10^{13} 倍.（注意，计算得到的 Q_2 已经足够接近 Q，这说明列符号的改变不可能解释这些误差. 如果你自己尝试实验后得到完全不同的结果，可能需要给 Q 的列和 R 的行乘上适当的因子 ± 1.）

看起来我们损失了 12 位准确数字. 但是，当把这些不准确的矩阵 Q_2 和 R_2 相乘时，奇妙的事情发生了：

```
norm(A-Q2*R2)/norm(A)            How accurate is Q2*R2?
    ans = 1.432e-15
```

乘积 Q_2R_2 达到了整整 15 位的准确度! 正如 Wilkinson 所说，Q_2 和 R_2 中的误差一定“有魔鬼般的相关性”. 在 10^{12} 分之一的精度上，它们在乘积 Q_2R_2 中相互抵消.

为了突出 Q_2R_2 的这种特殊准确性，再构造一对同样接近 Q, R 的矩阵 Q_3, R_3，并将它们相乘：

```
Q3 = Q+1e-4*randn(50);           Set Q3 to a random perturbation of Q
                                 that is closer to Q than Q2 is.
R3 = R+1e-4*randn(50);           Set R3 to a random perturbation of R
                                 that is closer to R than R2 is.
norm(A-Q3*R3)/norm(A)            How accurate is Q3*R3?
    ans = 0.00088
```

这一次，乘积中的误差很大.Q_2 并不比 Q_3 更好，R_2 也不比 R_3 更好，但 Q_2R_2 比 Q_3R_3 好 12 个数量级.

在这个实验中，我们没有费心让 R_3 变成上三角矩阵，也没有费心让 Q_3 变成正交矩阵；即使这样做，结果也不会有太大差别.

Q_2 和 R_2 中的误差是前向误差. 一般而言，大的前向误差可能来自病态问题，也可能来自不稳定算法（定理 15.1）. 在本实验中，误差来自前者. 通常，随机三角矩阵的列空间序列作为矩阵元素的函数是极其病态的.

Q_2R_2 中的误差是后向误差或残差. 这一误差很小，说明 Householder 三角化是后向稳定的.

定理

事实上，对所有矩阵 A 以及满足式 (13.5)、(13.7) 的所有计算机，Householder 三角化都是后向稳定的. 下面陈述这一结论. 和本书中的大多数稳定性结果一样，我们不给出证明.

结果的形式为

$$\widetilde{Q}\widetilde{R} = A + \delta A, \tag{16.1}$$

其中 δA 很小. 用文字说，计算得到的 Q 乘以计算得到的 R，等于给定矩阵 A 的一个小扰动.

不过，在使用这些符号时有一个微妙之处. 对于 $\widetilde{R}$，含义正如人们所预期：它是在浮点算术中通过 Householder 三角化构造出的上三角矩阵. 但是，对于 $\widetilde{Q}$，我们指的是一个恰好酉的矩阵.

回忆第 10 讲，精确的 Q 是乘积

$$Q = Q_1 Q_2 \cdots Q_n,$$

其中 Q_k 是由第 k 步算法 10.1 中确定的向量 v_k 按式 (10.4) 定义的 Householder 反射器. 在浮点计算中，我们得到的是向量序列 $\widetilde{v}_k$. 令 $\widetilde{Q}_k$ 表示由浮点向量 $\widetilde{v}_k$ 定义的、在数学上而不是在计算机上恰好酉的反射器. 现在定义

$$\widetilde{Q} = \widetilde{Q}_1 \widetilde{Q}_2 \cdots \widetilde{Q}_n. \tag{16.2}$$

这个恰好酉的矩阵 $\widetilde{Q}$ 将扮演“计算得到的 Q”的角色. 这个定义初看可能有些奇怪，但它是自然的. 正如第 10 讲所述，在应用中通常根本不会显式形成矩阵 Q，所以定义一个更直观的“计算 Q”并没有用. 真正显式形成的是这些向量，而它们正是式 (16.2) 中所使用的对象.

下面的定理解释了 MATLAB 实验中的现象.

定理 16.1. 设矩阵 $A \in \mathbb{C}^{m\times n}$ 的 QR 分解 $A = QR$ 通过 Householder 三角化（算法 10.1）在满足公理 (13.5)、(13.7) 的计算机上计算得到，并令计算因子 $\widetilde{Q}, \widetilde{R}$ 按上述方式定义. 那么存在 $\delta A \in \mathbb{C}^{m\times n}$，使得

$$\widetilde{Q}\widetilde{R} = A + \delta A, \qquad \frac{\|\delta A\|}{\|A\|} = O(\varepsilon_{\text{machine}}). \tag{16.3}$$

和本书一贯的用法一样，式 (16.3) 中的 $O(\varepsilon_{\text{machine}})$ 具有第 14 讲所说的精确定义. 当 $\varepsilon_{\text{machine}} \to 0$ 时，这个界对任意固定维数 m, n 的所有矩阵 A 一致成立，但不对 m, n 一致. 由于有限维向量空间上的所有范数都等价，无需指定范数（定理 14.1）.

分析求解 $Ax = b$ 的算法

我们已经看到，Householder 三角化是后向稳定的，但并不总是在前向意义下准确.（数值线性代数中的大多数矩阵分解也有同样的性质.）现在，QR 分解通常不是最终目的，而是求解方程组、最小二乘问题或特征值问题等其他任务的手段. 它的后向稳定性足以使它成为更大算法中的合格组件吗？换句话说，QR 乘积的准确性是否足够，还是还需要分别保证 Q 和 R 的准确性？

令人欣慰的答案是：对大多数目的而言，QR 乘积的准确性确实足够. 下面通过几个非常简单的论证说明这一点.

考虑使用 Householder 三角化求解非奇异 $m \times m$ 线性系统 $Ax = b$. 这一思想在第 7 讲结尾已经讨论过，下面给出更完整的算法陈述.

算法 16.1　用 QR 分解求解 $Ax = b$

$$
\begin{aligned}
QR &= A, && \text{按算法 10.1 将 } A \text{ 分解为 } QR\text{，其中 } Q \text{ 以反射器乘积表示；}\\
y &= Q^*b, && \text{按算法 10.2 构造 } Q^*b\text{；}\\
x &= R^{-1}y, && \text{用回代法求解三角系统 } Rx = y \text{（算法 17.1）．}
\end{aligned}
$$

这个算法是后向稳定的. 由于其中三个步骤各自都是后向稳定的，证明并不困难. 下面先陈述这三个步骤的后向稳定结果而不证明，再说明如何把它们组合起来.

算法 16.1 的第一步是对 A 做 QR 分解，得到计算矩阵 $\widetilde{R}, \widetilde{Q}$. 这一过程的后向稳定性已经由式 (16.3) 表达.

第二步是用算法 10.2 计算 $\widetilde{Q}^*b$.（注意，在这一论证中我们不写 Q^*b；因为此时第一步已经完成，计算产生的矩阵不是 Q，而是 $\widetilde{Q}$.）用算法 10.2 计算 $\widetilde{Q}^*b$ 时会产生舍入误差，因此结果不会恰好等于 $\widetilde{Q}^*b$，而是某个向量 $\widetilde{y}$. 可以证明，它满足如下后向稳定估计：

$$(\widetilde{Q} + \delta Q)\widetilde{y} = b, \qquad \|\delta Q\| = O(\varepsilon_{\text{machine}}). \tag{16.4}$$

和式 (16.3) 一样，这个等式是精确的. 换句话说，在浮点算术中应用 Householder 反射器，完全等价于用略有扰动的矩阵 $(\widetilde{Q} + \delta Q)^{-1}$ 乘以 b.

算法 16.1 的最后一步是计算 $\widetilde{R}^{-1}\widetilde{y}$ 的回代过程.（同样，在这个阶段可用的是 $\widetilde{R}$ 和 $\widetilde{y}$；R 和 y 与当前计算无关.）这一步会引入新的舍入误差，但计算仍然是后向稳定的. 这一次，估计为

$$(\widetilde{R} + \delta R)\widetilde{x} = \widetilde{y}, \qquad \frac{\|\delta R\|}{\|\widetilde{R}\|} = O(\varepsilon_{\text{machine}}). \tag{16.5}$$

和往常一样，左侧等式是精确的. 它说明浮点计算结果 $\widetilde{x}$ 正好是扰动系统 $\widetilde{R}x = \widetilde{y}$ 的精确解.

下一讲将完整推导式 (16.5)，而且过程比它听起来更有意思! 这个结果将在定理 17.1 中陈述.

现在把式 (16.3)–(16.5) 作为已知条件，就可以得到下面的定理. 这是数值线性代数中许多算法的后向稳定性定理都遵循的典型形式.

定理 16.2. 算法 16.1 是后向稳定的，满足

$$(A + \Delta A)\widetilde{x} = b, \qquad \frac{\|\Delta A\|}{\|A\|} = O(\varepsilon_{\text{machine}}) \tag{16.6}$$

其中 $\Delta A \in \mathbb{C}^{m\times m}$.

证明. 合并式 (16.4) 和 (16.5)，得到

$$
\begin{aligned}
b &= (\widetilde{Q} + \delta Q)(\widetilde{R} + \delta R)\widetilde{x}\\
&= [\widetilde{Q}\widetilde{R} + (\delta Q)\widetilde{R} + \widetilde{Q}(\delta R) + (\delta Q)(\delta R)]\widetilde{x}.
\end{aligned}
$$

因此，由式 (16.3)，

$$b = [A + \delta A + (\delta Q)\widetilde{R} + \widetilde{Q}(\delta R) + (\delta Q)(\delta R)]\widetilde{x}.$$

这个等式具有 $b = (A + \Delta A)\widetilde{x}$ 的形式，其中 ΔA 是四项之和. 要证明式 (16.6)，必须说明每一项相对于 A 都很小.

由于 $\widetilde{Q}\widetilde{R} = A + \delta A$ 且 $\widetilde{Q}$ 酉，有

$$\frac{\|\widetilde{R}\|}{\|A\|} \le \|\widetilde{Q}^*\| \frac{\|A + \delta A\|}{\|A\|} = O(1)$$

当 $\varepsilon_{\text{machine}} \to 0$ 时由式 (16.3) 得到.（如果 $\|\cdot\| = \|\cdot\|_2$，这个量是 $1 + O(\varepsilon_{\text{machine}})$；但我们没有对范数作任何假设.）由此以及式 (16.4)，

$$\frac{\|(\delta Q)\widetilde{R}\|}{\|A\|} \le \|\delta Q\| \frac{\|\widetilde{R}\|}{\|A\|} = O(\varepsilon_{\text{machine}}).$$

类似地，由式 (16.5)，

$$\frac{\|\widetilde{Q}(\delta R)\|}{\|A\|} \le \|\widetilde{Q}\| \frac{\|\delta R\|}{\|\widetilde{R}\|} \frac{\|\widetilde{R}\|}{\|A\|} = O(\varepsilon_{\text{machine}}).$$

最后，

$$\frac{\|(\delta Q)(\delta R)\|}{\|A\|} \le \|\delta Q\| \frac{\|\delta R\|}{\|A\|} = O(\varepsilon_{\text{machine}}^2).$$

因此总扰动 ΔA 满足

$$\begin{aligned} \frac{\|\Delta A\|}{\|A\|} &\le \frac{\|\delta A\|}{\|A\|} + \frac{\|(\delta Q)\widetilde{R}\|}{\|A\|} + \frac{\|\widetilde{Q}(\delta R)\|}{\|A\|} + \frac{\|(\delta Q)(\delta R)\|}{\|A\|} \\ &= O(\varepsilon_{\text{machine}}), \end{aligned}$$

证毕.

结合定理 12.2、15.1 和 16.2，可以得到关于 $Ax = b$ 解的准确度的如下结果.

定理 16.3. 算法 16.1 计算得到的解 $\widetilde{x}$ 满足

$$\frac{\|\widetilde{x} - x\|}{\|x\|} = O\big(\kappa(A)\varepsilon_{\text{machine}}\big). \tag{16.7}$$

习题

16.1 (a) 令固定的酉矩阵 $Q_1, \dots, Q_k \in \mathbb{C}^{m\times m}$，考虑对 $A \in \mathbb{C}^{m\times n}$ 计算乘积

$$B = Q_k \cdots Q_1 A.$$

假设计算从右到左进行，使用满足公理 (13.5)、(13.7) 的计算机上的直接浮点运算. 证明该算法是后向稳定的.（这里把 A 看作可以扰动的数据；矩阵 Q_j 固定且不允许扰动.）

(b) 给出一个例子，说明如果把酉矩阵 Q_j 换成任意矩阵 $X_j \in \mathbb{C}^{m\times m}$，上述结论就不再成立.

16.2 本题旨在进行一个与本讲 QR 分解实验类似的 SVD 实验.

(a) 编写 MATLAB 程序，构造 50×50 矩阵

$$A = USV^*,$$

其中 U, V 是随机正交矩阵，S 是对角矩阵，其对角元素是 $[0, 1]$ 中均匀分布的随机数，并按非增顺序排列. 让程序计算

$$[U_2, S_2, V_2] = \mathrm{svd}(A)$$

以及 $\|U - U_2\|$、$\|V - V_2\|$、$\|S - S_2\|$ 和 $\|A - U_2S_2V_2^*\|$. 对五个矩阵 A 做这项实验并评论结果.（提示：绘制 $\mathrm{diag}(U_2^*U)$ 和 $\mathrm{diag}(V_2^*V)$ 可能会有所帮助.）

(b) 固定所计算 SVD 中的符号，使 (a) 中的困难消失. 对五个随机矩阵重新运行程序，并评论各种范数. 它们与 $\mathrm{cond}(A)$ 有联系吗?

(c) 把 S 的对角元素替换成它们的六次方，重复 (b). 将本实验的结果与 QR 分解实验的结果相比，是否看到了显著差异?