数值线性代数　第 17 讲：回代法的稳定性

Lloyd N. Trefethen、David Bau III　中文阅读版

数值线性代数中最容易的问题之一，是求解三角形方程组. 标准算法是逐次代入；当系统为上三角系统时，称为回代. 本讲将完整说明这一算法是后向稳定的，并定量界定舍入误差的影响，而不只写成 “$O(\varepsilon_{\text{machine}})$”.

三角系统

我们已经看到，一般方程组 $Ax = b$ 可以通过 QR 分解化为上三角系统 $Rx = y$. 下三角和上三角系统还会出现在高斯消去、Cholesky 分解以及数值线性代数的许多其他计算中. 这些系统可以通过逐次代入轻松求解：下三角系统使用前代，上三角系统使用回代. 虽然这两种情形在数学上完全相同，但为明确起见，本讲只讨论回代.

设我们希望求解 $Rx = b$，即

$$\begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ & r_{22} & \cdots & r_{2m} \\ & & \ddots & \vdots \\ & & & r_{mm} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}. \tag{17.1}$$

其中 $b \in \mathbb{C}^m$，$R \in \mathbb{C}^{m\times m}$ 是非奇异上三角矩阵，未知量 $x \in \mathbb{C}^m$. 我们可以逐个求出 x 的分量，从 x_m 开始，最后得到 x_1. 为方便起见，下面把算法写成公式序列，而不是循环.

算法 17.1　回代

$$\begin{aligned} x_m &= b_m/r_{mm}, \\ x_{m-1} &= (b_{m-1} - x_m r_{m-1,m})/r_{m-1,m-1}, \\ x_{m-2} &= (b_{m-2} - x_{m-1} r_{m-2,m-1} - x_m r_{m-2,m})/r_{m-2,m-2}, \\ &\vdots \\ x_j &= \left(b_j - \sum_{k=j+1}^{m} x_k r_{jk} \right) / r_{jj}. \end{aligned}$$

这个结构是三角形的，每个位置都进行一次减法和一次乘法. 因此，运算量等于一个 $m \times m$ 三角形面积的两倍：

$$\text{回代的运算量 } \sim m^2 \text{ flops.} \tag{17.2}$$

后向稳定性定理

上一讲中，回代是用 QR 分解求解 $Ax = b$ 的三个步骤之一. 在式 (16.3)–(16.5) 中，我们断言这三个步骤都后向稳定，但没有证明. 本讲将填补其中一个缺口，推导一个能推出式 (16.5) 的界. 这一论证也展示了后向稳定性证明通常如何组织；本书只有这一处会把这类证明的全部细节都写出来.

不过，在证明算法 17.1 后向稳定之前，必须明确公式中尚未规定的一个细节. 我们任意约定：上面的括号表达式中，减法从左到右进行. 其他顺序同样稳定，只是估计的细节不同. 现在可以陈述定理.

定理 17.1. 将算法 17.1 应用于问题 (17.1)，其中数据是满足公理 (13.7) 的计算机上的浮点数. 则该算法后向稳定，即计算得到的解 $\widetilde{x} \in \mathbb{C}^m$ 满足

$$(R + \delta R)\widetilde{x} = b \tag{17.3}$$

其中 $\delta R \in \mathbb{C}^{m\times m}$ 为上三角矩阵，并且

$$\frac{\|\delta R\|}{\|R\|} = O(\varepsilon_{\text{machine}}). \tag{17.4}$$

更具体地，对每个 i, j，有

$$\left|\frac{\delta r_{ij}}{r_{ij}}\right| \le m\varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2). \tag{17.5}$$

在式 (17.5) 以及本讲全文中，我们沿用式 (14.12) 的约定：如果分母为零，则隐含断言分子也为零（对所有充分小的 $\varepsilon_{\text{machine}}$ 都成立）. 为使思想清晰而又不失趣味，下面用较舒缓的节奏给出证明.

$m = 1$

根据式 (17.3)，我们的任务是把每一个浮点误差表达为输入的扰动. 先考虑最简单的情形：R 是 1×1 矩阵. 此时回代只有一步，且记 $\oplus, \otimes, \ominus, \oslash$ 为浮点运算：

$$\widetilde{x}_1 = b_1 \oslash r_{11}.$$

由公理 (13.7)，计算得到的解满足

$$\widetilde{x}_1 = \frac{b_1}{r_{11}}(1 + \epsilon_1), \qquad |\epsilon_1| \le \varepsilon_{\text{machine}}.$$

但是，我们希望把误差表示为 R 的扰动. 令

$$\epsilon_1' = -\frac{\epsilon_1}{1 + \epsilon_1},$$

则

$$\widetilde{x}_1 = \frac{b_1}{r_{11}(1 + \epsilon_1')}, \qquad |\epsilon_1'| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2). \tag{17.6}$$

注意，ϵ_1' 等于 $-\epsilon_1$ 加上一个二阶项. 我们可以自由地把分子中的小相对扰动移到分母，或反过来移动；结果只会改变 $O(\varepsilon_{\text{machine}}^2)$ 的项（习题 14.2(b)）.

式 (17.6) 中的等号是精确等号，除法是数学除法而非浮点除法. 它说明 1×1 的回代是后向稳定的：$\widetilde{x}_1$ 正好是扰动问题的精确解，即

$$(r_{11}+\delta r_{11})\widetilde{x}_1 = b_1, \qquad \delta r_{11} = \epsilon_1' r_{11},$$

因而

$$\left|\frac{\delta r_{11}}{r_{11}}\right| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2).$$

$m = 2$

2×2 的情形稍微不那么简单. 设 $R\in\mathbb{C}^{2\times 2}$ 是上三角矩阵，$b\in\mathbb{C}^2$. 计算 $\widetilde{x}\in\mathbb{C}^2$ 分两步进行. 第一步与 1×1 情形相同：

$$\widetilde{x}_2 = b_2 \oslash r_{22} = \frac{b_2}{r_{22}(1+\epsilon_1')}, \qquad |\epsilon_1'| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2). \tag{17.7}$$

第二步为

$$\widetilde{x}_1 = (b_1 \ominus (\widetilde{x}_2 \otimes r_{12})) \oslash r_{11}.$$

要证明后向稳定性，必须把这三个浮点运算中的误差表达为条目 r_{ij} 的扰动.

乘法很简单，直接使用公理 (13.7)，把浮点乘法解释为 r_{12} 的扰动：

$$\widetilde{x}_1 = (b_1 \ominus \widetilde{x}_2 r_{12}(1+\epsilon_2)) \oslash r_{11}, \qquad |\epsilon_2| \le \varepsilon_{\text{machine}}.$$

除法和减法更微妙. 先按公理 (13.7) 用精确数学运算写出公式：

$$\widetilde{x}_1 = (b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_2))(1+\epsilon_3) \oslash r_{11} \tag{17.8}$$

$$= \frac{(b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_2))(1+\epsilon_3)}{r_{11}(1+\epsilon_4)}. \tag{17.9}$$

这里 $|\epsilon_3|, |\epsilon_4| \le \varepsilon_{\text{machine}}$. 像前面一样，把 ϵ_3, ϵ_4 从分子移到分母，得到

$$\widetilde{x}_1 = \frac{b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_2)}{r_{11}(1+\epsilon_3')(1+\epsilon_4')},$$

其中 $|\epsilon_3'|, |\epsilon_4'| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2)$. 等价地，

$$\widetilde{x}_1 = \frac{b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_2)}{r_{11}(1+2\epsilon_5)}, \qquad |\epsilon_5| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2). \tag{17.10}$$

这个公式说明：如果 r_{22}, r_{12}, r_{11} 分别被因子 $(1+\epsilon_1')$、$(1+\epsilon_2)$、$(1+2\epsilon_5)$ 扰动，那么 $\widetilde{x}$ 就是精确解. 这些扰动可以总结为

$$(R+\delta R)\widetilde{x} = b,$$

其中 δR 的条目满足（不等式按逐项理解）

$$\begin{bmatrix} |\delta r_{11}|/|r_{11}| & |\delta r_{12}|/|r_{12}| \\ & |\delta r_{22}|/|r_{22}| \end{bmatrix} = \begin{bmatrix} 2|\epsilon_5| & |\epsilon_2| \\ & |\epsilon_1'| \end{bmatrix} \le \begin{bmatrix} 2 & 1 \\ & 1 \end{bmatrix} \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2).$$

这就保证了在任意矩阵范数下 $\|\delta R\|/\|R\| = O(\varepsilon_{\text{machine}})$，从而 2×2 回代是后向稳定的.

$m = 3$

3×3 的分析包含一般情形所需的全部推理. 前两步与上面相同:

$$\widetilde{x}_3 = b_3 \oslash r_{33} = \frac{b_3}{r_{33}(1+\epsilon_1')}, \tag{17.11}$$

$$\widetilde{x}_2 = (b_2 \ominus (\widetilde{x}_3 \otimes r_{23})) \oslash r_{22} = \frac{b_2 - \widetilde{x}_3 r_{23}(1+\epsilon_2)}{r_{22}(1+2\epsilon_3')}. \tag{17.12}$$

其中

$$\begin{bmatrix} 2|\epsilon_3'| & |\epsilon_2| \\ & |\epsilon_1'| \end{bmatrix} \le \begin{bmatrix} 2 & 1 \\ & 1 \end{bmatrix} \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2).$$

第三步计算

$$\widetilde{x}_1 = [(b_1 \ominus (\widetilde{x}_2 \otimes r_{12})) \ominus (\widetilde{x}_3 \otimes r_{13})] \oslash r_{11}. \tag{17.13}$$

我们通过引入扰动 ϵ_4, ϵ_5，把式 (17.13) 中的两个乘法转化为数学乘法:

$$\widetilde{x}_1 = [(b_1 \ominus \widetilde{x}_2 r_{12}(1+\epsilon_4)) \ominus \widetilde{x}_3 r_{13}(1+\epsilon_5)] \oslash r_{11}.$$

再用 ϵ_6, ϵ_7 把减法转化为数学减法:

$$\widetilde{x}_1 = \big[(b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_4))(1+\epsilon_6) - \widetilde{x}_3 r_{13}(1+\epsilon_5)\big](1+\epsilon_7) \oslash r_{11}.$$

最后用 ϵ_8' 消去除法，其中 $|\epsilon_8'| \le \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2)$，并把结果放入分母:

$$\widetilde{x}_1 = \frac{\big[(b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_4))(1+\epsilon_6) - \widetilde{x}_3 r_{13}(1+\epsilon_5)\big](1+\epsilon_7)}{r_{11}(1+\epsilon_8')}.$$

上式已经包含我们需要的所有内容，除了 ϵ_6, ϵ_7 来自减法，它们若直接展开会影响 b_1，而我们的目标只允许扰动条目 r_{ij}. 含 ϵ_7 的项容易处理: 把它改写为 ϵ_7' 并像往常一样移入分母. 含 ϵ_6 的项需要一个新技巧: 也把它移入分母，但为了保持等式成立，同时在 r_{13} 项中补上新因子 $(1+\epsilon_6')$. 于是

$$\widetilde{x}_1 = \frac{b_1 - \widetilde{x}_2 r_{12}(1+\epsilon_4) - \widetilde{x}_3 r_{13}(1+\epsilon_5)(1+\epsilon_6')}{r_{11}(1+\epsilon_6')(1+\epsilon_7')(1+\epsilon_8')}.$$

现在 r_{13} 有两个至多为 $\varepsilon_{\text{machine}}$ 的扰动因子，而 r_{11} 有三个. 在这个公式中，计算的全部误差都已经表示为 R 的条目扰动.

结果可以总结为 $(R + \delta R)\widetilde{x} = b$，其中条目满足

$$\begin{bmatrix} |\delta r_{11}|/|r_{11}| & |\delta r_{12}|/|r_{12}| & |\delta r_{13}|/|r_{13}| \\ & |\delta r_{22}|/|r_{22}| & |\delta r_{23}|/|r_{23}| \\ & & |\delta r_{33}|/|r_{33}| \end{bmatrix} \le \begin{bmatrix} 3 & 1 & 2 \\ & 2 & 1 \\ & & 1 \end{bmatrix} \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2).$$

一般的 m

高维情形的分析类似. 例如，对 5×5 矩阵可以得到逐项界

$$\frac{|\delta R|}{|R|} \le \begin{bmatrix} 5 & 1 & 2 & 3 & 4 \\ & 4 & 1 & 2 & 3 \\ & & 3 & 1 & 2 \\ & & & 2 & 1 \\ & & & & 1 \end{bmatrix} \varepsilon_{\text{machine}} + O(\varepsilon_{\text{machine}}^2). \tag{17.14}$$

这个矩阵中的条目来自三个部分. 乘法 $\widetilde{x}_k r_{jk}$ 在如下模式的位置引入 $\varepsilon_{\text{machine}}$ 级扰动：

$$\otimes: \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ & 0 & 1 & 1 & 1 \\ & & 0 & 1 & 1 \\ & & & 0 & 1 \\ & & & & 0 \end{bmatrix}. \tag{17.15}$$

除以 r_{kk} 在如下模式的位置引入扰动：

$$\oslash: \begin{bmatrix} 1 & & & & \\ & 1 & & & \\ & & 1 & & \\ & & & 1 & \\ & & & & 1 \end{bmatrix}. \tag{17.16}$$

最后，减法也发生在式 (17.15) 的模式中；由于约定从左到右计算，每次减法都会在对角线以及其右侧的每个位置引入扰动. 累加后得到模式

$$\ominus: \begin{bmatrix} 4 & 0 & 1 & 2 & 3 \\ & 3 & 0 & 1 & 2 \\ & & 2 & 0 & 1 \\ & & & 1 & 0 \\ & & & & 0 \end{bmatrix}. \tag{17.17}$$

将式 (17.15)、(17.16) 和 (17.17) 相加，就得到式 (17.14). 定理 17.1 得证.

备注

导出式 (17.14) 的分析，是所有浮点计算后向误差分析的典型例子. 唯一的原始工具是浮点公理 (13.7)：它保证每个运算 $\oplus, \ominus, \otimes, \oslash$（有时还包括浮点平方根）引入一个小的相对误差. 我们反复而谨慎地使用这一公理，把计算过程中的每个误差解释为初始数据中

的误差. 由于差异只达到 $O(\varepsilon_{\text{machine}}^2)$，$\varepsilon_{\text{machine}}$ 量级的扰动可以相加，也可以自由地在分子和分母之间移动.

对同一个算法，可以导出不止一种误差界. 在本例中，也可以同时扰动 b_j 和 r_{ij}，这样就不必使用式 (17.17) 所代表的技巧. 另一方面，最终只扰动 R 的结果看起来更简洁.

式 (17.5) 是一个逐项后向误差界：每个条目 r_{ij} 都按照相对于自身的大小发生小扰动，而不只是相对于 R 的范数发生扰动. 例如，如果 $r_{ij} = 0$，这个条目完全不发生扰动；δR 与 R 具有相同的稀疏模式. 数值线性代数中的一些算法满足分量级后向误差估计，另一些则不满足；后一种情形必须采用式 (17.4) 那样较弱的范数级估计. 第二次世界大战后数值分析的早期年代，大多数误差估计都是范数级的；近几十年，研究逐渐转向分量级分析，因为这类结果更尖锐，而且满足分量级界的算法对变量缩放不那么敏感. 本书不再展开这些问题.

最后说明式 (17.5) 或 (17.14) 这样的定量界，与用 $O(\varepsilon_{\text{machine}})$ 记号表达的式 (17.4) 之间的关系. 为什么不干脆省略式 (17.4) 这样的粗略陈述？原因是定量界必须包含 $\sqrt{m}$ 或 m 等因子，而且依赖于范数，难以记忆；由于统计性的抵消，在实践中它们往往还过于保守. 因此，我们更喜欢用 $O(\varepsilon_{\text{machine}})$ 表达大多数结果；这也是数值分析家最容易记住的形式.

习题

17.1 对任意给定的范数 $\|\cdot\|$，界 (17.5) 都比 (17.4) 给出更定量的范数级界. 分别对下列范数推导这样的界：

(a) $\|\cdot\|_1$；

(b) $\|\cdot\|_2$；

(c) $\|\cdot\|_\infty$.

17.2 三角系统 (17.1) 使用回代求解. 定理 17.1 对误差 $\|\widetilde{x} - x\|$ 究竟意味着什么？

17.3 设 $L \in \mathbb{C}^{m\times m}$ 是单位下三角矩阵（即对角线元素都等于 1）. 为方便起见，将 L 写成

$$L = \begin{bmatrix} 1 & & & & \\ -\ell_{2,1} & 1 & & & \\ -\ell_{3,1} & -\ell_{3,2} & 1 & & \\ \vdots & \vdots & \ddots & \ddots & \\ -\ell_{m,1} & -\ell_{m,2} & -\ell_{m,3} & \cdots & 1 \end{bmatrix},$$

并定义 $M = L^{-1}$.

(a) 推导 m_{ij} 的公式（公式中可以包含 M 的其他条目）. m_{ij} 依赖 L 的哪些条目？

(b) 假设 L 的次对角线条目是相互独立、等概率取 ± 1 的随机数. 固定 k，定义 $\mu_1 = m_{k,k}$、$\mu_2 = m_{k+1,k}$、$\mu_3 = m_{k+2,k}$、…. 为这些 μ_j 写出带随机系数的递推关系组.

(c) 实验表明, 条目为 ± 1 的随机三角矩阵按指数速度病态: 若 κ_m 表示这类 $m \times m$ 矩阵的 2-范数条件数，则

$$\lim_{m\to\infty} (\kappa_m)^{1/m} = C$$

对某个 $1 < C < 1.5$ 的常数 C 成立.（这个极限可以用多种方式更精确地表述，但这里不讨论技术细节；可以把它理解为“以概率 1 成立”.）对不同维数的随机矩阵进行数值实验，将 C 的估计精确到 10% 以内，或达到更高精度.

(d) 如果把 (c) 中的随机矩阵替换成 (b) 中的随机序列 $\mu_1, \mu_2, \mu_3, \ldots$，就可以进行更大规模的实验. 解释（不要求证明）为什么也可以通过研究这些序列得到常数 C，并进行数值实验，将 C 的估计精确到 1% 以内，或达到更高精度.