数值线性代数　第 23 讲：Cholesky 分解

Lloyd N. Trefethen、David Bau III　中文阅读版

Hermitian 正定矩阵可以用三角因子分解，而且运算量只有一般矩阵的一半。实现这一点的标准算法是 Cholesky 分解。它是高斯消去法的一个变体，同时在矩阵的左侧和右侧操作，从而保持并利用对称结构。

Hermitian 正定矩阵

实矩阵 $A \in \mathbb{R}^{m\times m}$ 如果关于主对角线对称，即 $a_{ij} = a_{ji}$，就称为对称矩阵，因而 $A = A^T$。这样的矩阵满足

$$x^T Ay = y^T Ax, \qquad x, y \in \mathbb{R}^m.$$

对复矩阵 $A \in \mathbb{C}^{m\times m}$，相应的性质是 Hermitian 性：主对角线下方的条目是主对角线上方对应条目的复共轭，$a_{ij} = \overline{a_{ji}}$，因而 $A = A^*$。（这些定义已经在第 2 讲出现过。）注意，Hermitian 矩阵的对角线条目必为实数。

Hermitian 矩阵满足

$$x^* Ay = y^* Ax, \qquad x, y \in \mathbb{C}^m.$$

特别地，对任意 $x \in \mathbb{C}^m$，x^*Ax 都是实数。如果进一步对所有 $x \neq 0$ 都有 $x^*Ax > 0$，则称 A 为 Hermitian 正定矩阵，有时也简称正定矩阵。物理系统中出现的许多矩阵，由于基本物理定律，都是 Hermitian 正定的。

设 A 是 $m \times m$ 的 Hermitian 正定矩阵，X 是满列秩的 $m \times n$ 矩阵，且 $m \geq n$。那么 X^*AX 也是 Hermitian 正定的。它是 Hermitian 矩阵，因为

$$(X^*AX)^* = X^*A^*X = X^*AX.$$

它是正定的，因为对任意 $x \neq 0$，有 $Xx \neq 0$，从而

$$x^*(X^*AX)x = (Xx)^*A(Xx) > 0.$$

取每列只有一个 1、其余元素为 0 的 X，可以把 A 的任意主子矩阵写成 X^*AX。因此，A 的任意主子矩阵都必须正定；特别地，A 的每个对角线条目都是正实数。

Hermitian 正定矩阵的特征值也都是正实数。若 $Ax = \lambda x$ 且 $x \neq 0$，则

$$x^*Ax = \lambda x^*x > 0,$$

所以 $\lambda > 0$。反过来可以证明，如果 Hermitian 矩阵的全部特征值为正，那么它就是正定的。

Hermitian 矩阵对应于不同特征值的特征向量彼此正交。（下一讲会讨论，Hermitian 矩阵是正规矩阵。）设 $Ax_1 = \lambda_1 x_1$、$Ax_2 = \lambda_2 x_2$ 且 $\lambda_1 \neq \lambda_2$。那么

$$\lambda_2 x_1^* x_2 = x_1^* A x_2 = x_2^* A x_1 = \overline{\lambda_1} x_2^* x_1 = \lambda_1 x_1^* x_2,$$

于是 $(\lambda_1 - \lambda_2) x_1^* x_2 = 0$，从而 $x_1^* x_2 = 0$。

对称高斯消去

现在讨论如何把 Hermitian 正定矩阵分解为三角因子。先考察一个左上角为 1 的 Hermitian 矩阵，对它执行一步高斯消去：

$$A = \begin{bmatrix} 1 & w^* \\ w & K \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ w & I \end{bmatrix} \begin{bmatrix} 1 & w^* \\ 0 & K - ww^* \end{bmatrix}.$$

正如第 20 讲所述，左侧的初等下三角操作从后续各行中减去第一行的适当倍数，从而在矩阵的第一列引入零。

普通高斯消去法接下来会继续在第二列引入零。不过，为了保持对称性，Cholesky 分解首先在第一行引入与第一列相匹配的零。可以通过右侧的上三角操作做到这一点，即从后续各列中减去第一列的适当倍数：

$$\begin{bmatrix} 1 & w^* \\ 0 & K - ww^* \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & K - ww^* \end{bmatrix} \begin{bmatrix} 1 & w^* \\ 0 & I \end{bmatrix}.$$

注意，这个上三角操作恰好是前面用来在第一列引入零的下三角操作的伴随。把两个操作合并，得到

$$A = \begin{bmatrix} 1 & 0 \\ w & I \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & K - ww^* \end{bmatrix} \begin{bmatrix} 1 & w^* \\ 0 & I \end{bmatrix}. \tag{23.1}$$

Cholesky 分解的思想，就是以这种方式继续进行：对 A 的一列和一行同时引入零，直到它被化为单位矩阵。

Cholesky 分解

为了使这种对称三角化对一般情形都有效，我们需要允许任意 $a_{11} > 0$，而不只是 $a_{11} = 1$。在 (23.1) 中把 R_1 的某些元素乘以 $\sqrt{a_{11}}$ 即可完成推广。令 $\alpha = \sqrt{a_{11}}$，则

$$\begin{aligned} A &= \begin{bmatrix} a_{11} & w^* \\ w & K \end{bmatrix} \\ &= \begin{bmatrix} \alpha & 0 \\ w/\alpha & I \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & K - ww^*/a_{11} \end{bmatrix} \begin{bmatrix} \alpha & w^*/\alpha \\ 0 & I \end{bmatrix} = R_1^* A_1 R_1. \end{aligned}$$

这就是 Cholesky 分解反复使用的基本步骤。如果子矩阵 $K - ww^*/a_{11}$ 的左上角条目为正，就可以对它使用同一个公式。于是 $A_1 = R_2^* A_2 R_2$，从而 $A = R_1^* R_2^* A_2 R_2 R_1$。继续到右下角，最终得到

$$A = R_1^* R_2^* \cdots R_m^* R_m \cdots R_2 R_1. \tag{23.2}$$

把前半段记作 R^*、后半段记作 R，就有

$$A = R^* R, \qquad r_{jj} > 0, \tag{23.3}$$

其中 R 是上三角矩阵。Hermitian 正定矩阵的这种分解称为 Cholesky 分解。

上面的描述还留下一个问题：我们怎么知道子矩阵 $K - ww^*/a_{11}$ 的左上角条目为正？答案是，它必须为正，因为 $K - ww^*/a_{11}$ 是正定的。事实上，它是正定矩阵 $R_1^{-*} A R_1^{-1}$ 的右下角 $(m-1) \times (m-1)$ 主子矩阵。用归纳法可以得到，在分解过程中出现的所有子矩阵 A_i 都是正定的，因此算法不可能中途失败。

定理 23.1. 每个 Hermitian 正定矩阵 $A \in \mathbb{C}^{m \times m}$ 都有唯一的 Cholesky 分解 (23.3)。

证明. 存在性正是上面的讨论：算法不可能失败，所以分解一定存在。事实上，算法也给出了唯一性。在每一步 (23.2) 中，$\alpha = \sqrt{a_{11}}$ 的值由 R^*R 的形式唯一确定；一旦 α 确定，R_1^* 的第一行也唯一确定。每一步都如此，因此整个分解唯一。 □

算法

实现 Cholesky 分解时，只需要显式存储正在操作的矩阵的一半，因而可以省去一半算术运算。下面给出算法的一种正式写法。输入矩阵 A 表示待分解的 $m \times m$ Hermitian 正定矩阵的上三角部分；实际软件可以使用压缩存储，避免浪费方阵数组的一半空间。输出矩阵 R 是满足 $A = R^*R$ 的上三角因子。每次外层迭代对应一次基本分解；在第 k 步，子矩阵 $R^*_{k:m,k:m}$ 的上三角部分表示当前待分解的 Hermitian 矩阵的上三角部分。

算法 23.1（Cholesky 分解）

```
R = A
for k = 1 to m
    for j = k+1 to m
        R(j,j:m) = R(j,j:m) - R(k,j:m)*R(k,j)/R(k,k)
    R(k,k:m) = R(k,k:m)/sqrt(R(k,k))
```

运算量

Cholesky 分解的算术量主要集中在内层循环。内层语句

$$R_{j,j:m} = R_{j,j:m} - R_{k,j:m} R_{kj} / R_{kk}$$

每执行一次，需要一次除法、$m-j+1$ 次乘法和 $m-j+1$ 次减法，总计约 $2(m-j)$ 次浮点运算。对每个 $j=k+1,\ldots,m$ 重复，再对每个 $k=1,\ldots,m$ 重复。因此

$$\begin{aligned}\sum_{k=1}^{m}\sum_{j=k+1}^{m}2(m-j) &\sim 2\sum_{k=1}^{m}\sum_{j=1}^{k}j \sim \sum_{k=1}^{m}k^2\\ &\sim \frac{1}{3}m^3 \text{ flops.}\end{aligned}$$

所以，Cholesky 分解的运算量只有高斯消去法的一半；对同一个矩阵，高斯消去法需要约 $\frac{2}{3}m^3$ 次浮点运算。

运算量也可以用几何方式计算。对每个 k，三角层的每个位置进行两次浮点运算（一次乘法和一次减法）。整个算法相当于堆叠 m 层：

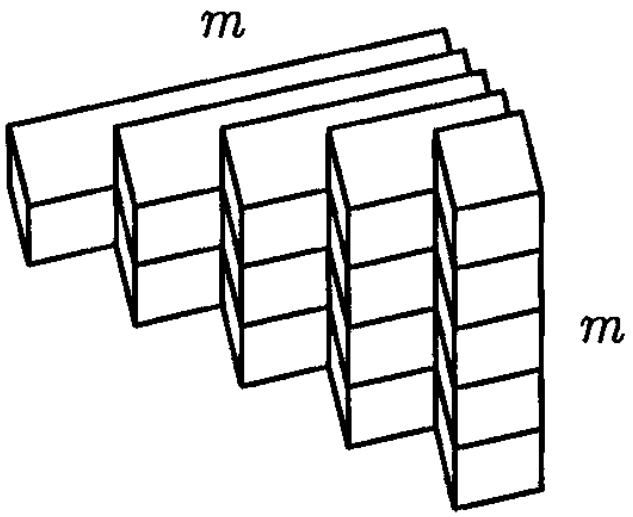


图 1: Cholesky 分解运算量的几何示意图。

当 $m\to\infty$ 时，这个实体趋近于体积为 $\frac{1}{6}m^3$ 的四面体。由于每个单位立方体对应两次浮点运算，再次得到

$$\text{Cholesky 分解的工作量} \sim \frac{1}{3}m^3 \text{ flops.} \tag{23.4}$$

稳定性

高斯消去法稳定性分析中的所有微妙之处，在 Cholesky 分解中都消失了。这个算法总是稳定的。直观地说，这是因为因子 R 不可能变得很大。例如在 2-范数下，

$$\|R\| = \|R^*\| = \|A\|^{1/2},$$

其中等式可由奇异值分解证明；对满足 $1\le p\le\infty$ 的其他 p-范数，$\|R\|$ 与 $\|A\|^{1/2}$ 的差别也不会超过一个 $\sqrt{m}$ 的因子。因此，远大于 A 的条目不可能在计算中出现。

注意，Cholesky 分解不需要任何选主元就能保持稳定。直观上，这与 Hermitian 正定矩阵的大部分权重集中在对角线上有关。例如不难证明，最大条目必定出现在对角线上；而这个性质也会传递给归纳过程 (23.2) 中构造出的正定子矩阵。

对 Cholesky 过程进行稳定性分析，可以得到下面的向后稳定性结论。

定理 23.2. 设 $A \in \mathbb{C}^{m\times m}$ 是 Hermitian 正定矩阵，并在满足 (13.5) 和 (13.7) 的计算机上利用算法 23.1 计算其 Cholesky 分解。当 $\varepsilon_{\text{machine}}$ 足够小时，该过程保证完成（不会出现零或负的角元素 r_{kk}），并产生满足下式的计算因子 $\widetilde{R}$:

$$\widetilde{R}^*\widetilde{R} = A + \delta A, \qquad \frac{\|\delta A\|}{\|A\|} = O(\varepsilon_{\text{machine}}), \qquad \delta A \in \mathbb{C}^{m\times m}. \tag{23.5}$$

如果 A 病态，$\widetilde{R}$ 通常不会接近 R；我们最多只能说

$$\frac{\|\widetilde{R} - R\|}{\|R\|} = O\big(\kappa(A)\varepsilon_{\text{machine}}\big).$$

换句话说，Cholesky 分解一般是一个病态问题。真正满足较好误差界 (23.5) 的是乘积 $\widetilde{R}^*\widetilde{R}$。因此，$\widetilde{R}$ 中的舍入误差虽然可能很大，却是“恶魔般相关”的，正如第 16 讲 QR 分解中看到的那样。

求解 $Ax = b$

如果 A 是 Hermitian 正定矩阵，求解方程组 $Ax = b$ 的标准方法就是 Cholesky 分解。算法 23.1 把方程组化为

$$R^*Rx = b,$$

然后依次求解两个三角方程组：先求未知量 y，$R^*y = b$；再求未知量 x，$Rx = y$。每次三角求解只需约 $\frac{1}{2}m^2$ 次浮点运算，所以总工作量仍为约 $\frac{1}{3}m^3$ 次浮点运算。

按照与第 16 讲类似的推理，可以证明这个过程是向后稳定的。

定理 23.3. 通过 Cholesky 分解（算法 23.1）求解 Hermitian 正定方程组 $Ax = b$ 是向后稳定的；所得计算解 $\widetilde{x}$ 满足

$$(A + \Delta A)\widetilde{x} = b, \qquad \frac{\|\Delta A\|}{\|A\|} = O(\varepsilon_{\text{machine}}), \qquad \Delta A \in \mathbb{C}^{m\times m}. \tag{23.6}$$

习题

23.1. 设 A 是非奇异方阵，并设 $A = QR$、$A^*A = U^*U$ 分别是 QR 分解和 Cholesky 分解，且采用通常的归一化 $r_{jj}, u_{jj} > 0$。$R = U$ 是真还是假?

23.2. 以定理 16.2 的证明为指导，由定理 23.2 和定理 17.1 推导定理 23.3。

23.3. 反向软件工程：MATLAB 的反斜杠。

下面的 MATLAB 会话记录了在一台 1991 年制造的工作站上，对若干计算测量耗时的一系列测试。对每一项，尝试解释：(i) 为什么要进行这个实验；(ii) 为什么会得到这样的结果。答案应引用正文中的浮点运算量公式。MATLAB 命令 help chol 和 help slash 可能会帮助你完成这项侦探工作。

```
(a) m = 200; Z = randn(m,m);
    A = Z'*Z; b = randn(m,1);
    tic; x = A\b; toc;
         elapsed_time = 1.0368

(b) tic; x = A\b; toc;
         elapsed_time = 1.0303

(c) A2 = A; A2(m,1) = A2(m,1)/2;
    tic; x = A2\b; toc;
         elapsed_time = 2.0361

(d) I = eye(m,m); emin = min(eig(A));
    A3 = A - .9*emin*I;
    tic; x = A3\b; toc;
         elapsed_time = 1.0362

(e) A4 = A - 1.1*emin*I;
    tic; x = A4\b; toc;
         elapsed_time = 2.9624

(f) A5 = triu(A);
    tic; x = A5\b; toc;
         elapsed_time = 0.1261

(g) A6 = A5; A6(m,1) = A5(1,m);
    tic; x = A6\b; toc;
         elapsed_time = 2.0012
```