数值线性代数　第 27 讲：Rayleigh 商与逆迭代

Lloyd N. Trefethen、David Bau III　中文阅读版

本讲介绍几个经典的特征值算法。它们各自在特定场景下很有用，尤其是逆迭代：当某个特征值已经知道时，逆迭代是计算对应特征向量的标准方法。把这些工具组合起来，就得到著名的 QR 算法；QR 算法将在接下来的两讲中讨论。

限制到实对称矩阵

在数值线性代数中，大多数算法思想既适用于一般矩阵，也适用于经过一些简化的 Hermitian 矩阵。对于本讲以及接下来的三讲，这种情形仍然成立，但一般矩阵与 Hermitian 矩阵之间的差异会比较明显。因此，本四讲暂时只考虑实对称矩阵，并且始终假设所用范数为 2-范数：

$$A = A^T \in \mathbb{R}^{m\times m}, \qquad x \in \mathbb{R}^m, \qquad x^* = x^T, \qquad \|x\| = \sqrt{x^T x}.$$

特别地，A 的特征值都是实数，并且存在一组完备的正交特征向量。记

$$\text{实特征值：}\ \lambda_1, \ldots, \lambda_m, \qquad \text{标准正交特征向量：}\ q_1, \ldots, q_m.$$

特征向量按 $\|q_j\| = 1$ 归一化；特征值的排序将在需要时具体说明。

接下来几讲的大多数思想属于第 25 讲介绍的两个阶段中的第二阶段。也就是说，真正应用这些思想时，A 不仅是实对称矩阵，通常还已经是三对角矩阵。三对角结构有时具有数学上的重要性，例如可以帮助选择 QR 算法的移位；它始终具有算法上的重要性，因为它可以把许多步骤的工作量从 $O(m^3)$ 降到 $O(m)$，本讲末尾会具体说明。

Rayleigh 商

向量 $x \in \mathbb{R}^m$ 的 Rayleigh 商定义为标量

$$r(x) = \frac{x^T A x}{x^T x}. \tag{27.1}$$

如果 x 是特征向量，那么 $r(x) = \lambda$，其中 λ 是对应的特征值。这个公式的一种动机是：给定 x，什么标量 α 最像 x 对应的“特征值”，使得 $\|Ax - \alpha x\|_2$ 最小？这是一个形如 $x\alpha \approx Ax$ 的 $m \times 1$ 最小二乘问题，其中 α 是未知标量，而 Ax 是右端项。对这个系统写

出正规方程（式 (11.9)），就得到 $\alpha = r(x)$。因此，如果 x 接近但不一定等于特征向量，$r(x)$ 是一个自然的特征值估计。

为了定量研究这个想法，把 $x \in \mathbb{R}^m$ 看作变量，于是 r 是从 $\mathbb{R}^m$ 到 $\mathbb{R}$ 的函数。我们关心 x 接近特征向量时 $r(x)$ 的局部行为。对坐标 x_j 求偏导：

$$\frac{\partial r(x)}{\partial x_j} = \frac{2(Ax)_j}{x^T x} - \frac{2(x^T A x)x_j}{(x^T x)^2} = \frac{2}{x^T x}\big(Ax - r(x)x\big)_j.$$

把这些偏导数组成一个 m-向量，就得到 $r(x)$ 的梯度：

$$\nabla r(x) = \frac{2}{x^T x}\big(Ax - r(x)x\big). \tag{27.2}$$

由此可见，在 A 的特征向量处，$r(x)$ 的梯度为零。反过来，如果 $x \neq 0$ 且 $\nabla r(x) = 0$，那么 x 就是特征向量，$r(x)$ 是对应的特征值。

从几何上看，A 的特征向量是函数 $r(x)$ 的驻点，而特征值是 $r(x)$ 在这些驻点处的函数值。由于 $r(x)$ 与 x 的尺度无关，驻点实际上位于经过原点的直线上。若把 x 限制在单位球面 $\|x\| = 1$ 上，那么在特征值互异时，这些驻点就成为彼此孤立的点：

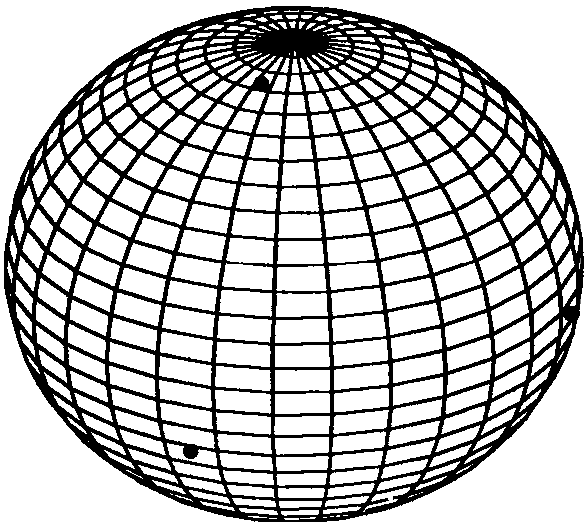


图 1: 单位球面上的 Rayleigh 商。$r(x)$ 在 $\|x\| = 1$ 上连续，其驻点是归一化特征向量；图示 $m = 3$ 时的三个正交驻点及其对跖点。

令 q_j 是 A 的一个特征向量。由 $\nabla r(q_j) = 0$ 以及 $r(x)$ 的光滑性（除了原点 $x = 0$ 外处处光滑），可得一个重要结论：

$$r(x) - r(q_j) = O\big(\|x - q_j\|^2\big), \qquad x \to q_j. \tag{27.3}$$

因此，Rayleigh 商是特征值的二阶精度估计；这正是它强大的地方。

还可以更直接地推导 (27.3)。把 x 展开为 A 的特征向量 $q_1, \dots, q_m$ 的线性组合。若 $x = \sum_{j=1}^{m} a_j q_j$，则

$$r(x) = \frac{\sum_{j=1}^{m} a_j^2 \lambda_j}{\sum_{j=1}^{m} a_j^2}.$$

所以 $r(x)$ 是 A 的特征值的加权平均，权重是 x 在特征向量基下坐标的平方。正因为坐标被平方，如果对所有 $j \neq J$ 都有 $|a_j/a_J| \leq \epsilon$，那么 $r(x) - r(q_J) = O(\epsilon^2)$。

幂迭代

现在换一个方向。设 $v^{(0)}$ 是满足 $\|v^{(0)}\| = 1$ 的向量。下面的过程称为幂迭代；第 25 讲开头曾把它作为一个不太好的想法提到过。幂迭代有望产生一个序列 $v^{(k)}$，使其收敛到对应于 A 的最大特征值的特征向量。

算法 27.1（幂迭代）

```
v^(0) = some vector with ||v^(0)|| = 1
for k = 1, 2, ...
      w = A v^(k-1)                          apply A
      v^(k) = w / ||w||                       normalize
      lambda^(k) = (v^(k))^T A v^(k)          Rayleigh quotient
```

本讲以及后续算法都不讨论终止条件，只用“for $k = 1, 2, \ldots$”这一提示性表达式描述循环。实际计算中，终止条件当然非常重要；这也是 LAPACK 或 MATLAB 中的高质量软件通常优于个人临时编写程序的地方之一。

幂迭代很容易分析。把 $v^{(0)}$ 写成标准正交特征向量的线性组合：

$$v^{(0)} = a_1 q_1 + a_2 q_2 + \cdots + a_m q_m.$$

因为 $v^{(k)}$ 是 $A^k v^{(0)}$ 的倍数，所以存在常数 c_k，使得

$$\begin{aligned} v^{(k)} &= c_k A^k v^{(0)} \\ &= c_k \big(a_1 \lambda_1^k q_1 + a_2 \lambda_2^k q_2 + \cdots + a_m \lambda_m^k q_m \big) \\ &= c_k \lambda_1^k \big(a_1 q_1 + a_2 (\lambda_2/\lambda_1)^k q_2 + \cdots + a_m (\lambda_m/\lambda_1)^k q_m \big). \end{aligned} \tag{27.4}$$

由此得到以下结论。

定理 27.1. 假设 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_m| \geq 0$，并且 $q_1^T v^{(0)} \neq 0$。那么算法 27.1 的迭代满足

$$\|v^{(k)} - (\pm q_1)\| = O\left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right), \qquad |\lambda^{(k)} - \lambda_1| = O\left(\left| \frac{\lambda_2}{\lambda_1} \right|^{2k} \right), \tag{27.5}$$

当 $k \to \infty$ 时成立。这里的 $\pm$ 表示：对每个 k，应选取两个符号中的一个，然后相应的界成立。

证明很直接。第一个结论由 (27.4) 得到，因为 $a_1 = q_1^T v^{(0)} \neq 0$；第二个结论由第一个结论和 (27.3) 得到。如果 $\lambda_1 > 0$，那么每一步的符号要么全为 $+$，要么全为 $-$；如果 $\lambda_1 < 0$，符号则交替出现。

(27.5) 以及下面类似公式中的 $\pm$ 符号并不十分美观。一个优雅的办法是讨论子空间而不是向量，例如说 $(v^{(k)})$ 收敛到 (q_1)。不过，为了避免引入子空间收敛的精确定义，本书不采用这种写法。

幂迭代单独使用时用途有限，原因有几个。首先，它只能找到对应于最大特征值的特征向量。其次，它只有线性收敛，每次迭代只把误差缩小约 $|\lambda_2/\lambda_1|$ 倍。最后，这个因子的质量取决于最大特征值是否明显大于其他特征值；如果最大的两个特征值模很接近，收敛就会很慢。幸运的是，有办法放大特征值之间的差异。

逆迭代

对任意不是 A 的特征值的实数 μ，矩阵 $(A - \mu I)^{-1}$ 与 A 具有相同的特征向量，对应的特征值为

$$\{(\lambda_j - \mu)^{-1}\},$$

其中 $\{\lambda_j\}$ 是 A 的特征值。这启发了一个想法：假设 μ 接近 A 的某个特征值 λ_J，那么 $(\lambda_J - \mu)^{-1}$ 的模可能远大于对所有 $j \neq J$ 的 $(\lambda_j - \mu)^{-1}$。于是，对 $(A - \mu I)^{-1}$ 应用幂迭代，过程就会快速收敛到 q_J。这个想法称为逆迭代。

算法 27.2（逆迭代）

```
v^(0) = some vector with ||v^(0)|| = 1
for k = 1, 2, ...
      Solve (A - mu I) w = v^(k-1) for w    apply (A - mu I)^(-1)
      v^(k) = w / ||w||                     normalize
      lambda^(k) = (v^(k))^T A v^(k)        Rayleigh quotient
```

如果 μ 是 A 的特征值，$A - \mu I$ 就是奇异的；如果 μ 非常接近特征值，$A - \mu I$ 可能病态到无法准确求解 $(A - \mu I)w = v^{(k-1)}$。这些看似严重的陷阱实际上不会造成问题，见习题 27.5。

和幂迭代一样，逆迭代只有线性收敛。但与幂迭代不同，我们可以通过提供特征值估计 μ 来选择最终找到的特征向量。而且，线性收敛速率可以控制，因为它取决于 μ 的质量：如果 μ 比其他特征值都更接近某一个特征值，那么 $(A - \mu I)^{-1}$ 的最大特征值就会远大于其余特征值。沿用幂迭代的推理可得以下定理。

定理 27.2. 假设 λ_J 是离 μ 最近的特征值，λ_K 是第二近的特征值，即

$$|\mu - \lambda_J| < |\mu - \lambda_K| \le |\mu - \lambda_j|, \qquad j \ne J,$$

并且 $q_J^T v^{(0)} \ne 0$。那么算法 27.2 的迭代满足

$$\|v^{(k)} - (\pm q_J)\| = O\left(\left|\frac{\mu - \lambda_J}{\mu - \lambda_K}\right|^k\right), \qquad |\lambda^{(k)} - \lambda_J| = O\left(\left|\frac{\mu - \lambda_J}{\mu - \lambda_K}\right|^{2k}\right),$$

当 $k \to \infty$ 时成立，其中 $\pm$ 的含义与定理 27.1 相同。

如果特征值已经知道，逆迭代是数值线性代数中最有价值的工具之一：它是计算一个或多个特征向量的标准方法。此时直接按算法 27.2 执行，但不再计算 Rayleigh 商即可。

Rayleigh 商迭代

到目前为止，本讲给出了两种互补的办法：由特征向量估计得到特征值估计（Rayleigh 商），以及由特征值估计得到特征向量估计（逆迭代）。把二者结合起来是很自然的：

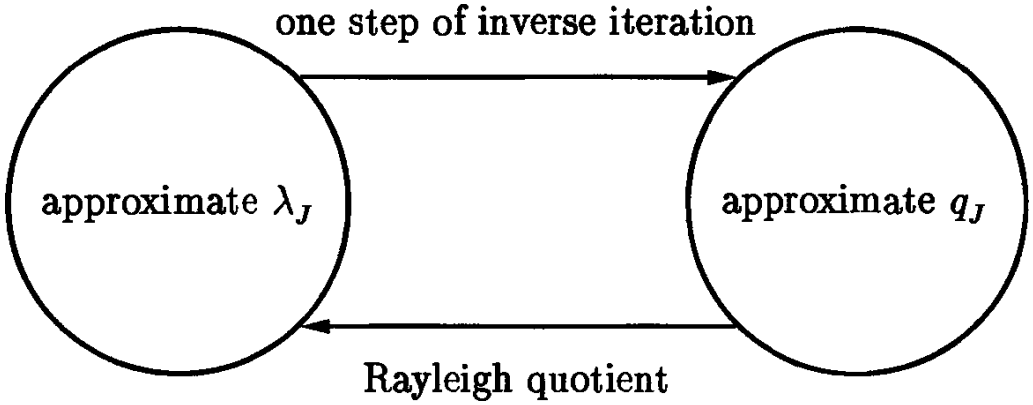


图 2: Rayleigh 商迭代的思想：一次逆迭代把特征值估计变成特征向量估计，Rayleigh 商再把特征向量估计变回特征值估计。原书特别说明该图是简化示意；从近似 λ_J 得到近似 q_J 还需要一个初始的 q_J 近似。

这个想法是：不断改进特征值估计，从而在每一步提高逆迭代的收敛速率。所得算法称为 Rayleigh 商迭代。

算法 27.3（Rayleigh 商迭代）

```
v^(0) = some vector with ||v^(0)|| = 1
lambda^(0) = (v^(0))^T A v^(0) = corresponding Rayleigh quotient
for k = 1, 2, ...
      Solve (A - lambda^(k-1) I) w = v^(k-1) for w
          apply (A - lambda^(k-1) I)^(-1)
```

```
v^(k) = w / ||w||                    normalize
lambda^(k) = (v^(k))^T A v^(k)       Rayleigh quotient
```

这个算法的收敛速度极其惊人：每次迭代都会把准确数字的数量大致提高到原来的三倍。

定理 27.3. Rayleigh 商迭代对除一个测度为零的初始向量集合之外的所有 $v^{(0)}$，都收敛到一个特征值/特征向量对。若它收敛，并且 λ_J 是 A 的特征值、$v^{(0)}$ 足够接近特征向量 q_J，则最终具有三次收敛性：

$$\|v^{(k+1)} - (\pm q_J)\| = O\left(\|v^{(k)} - (\pm q_J)\|^3\right), \tag{27.6}$$

以及

$$|\lambda^{(k+1)} - \lambda_J| = O\left(|\lambda^{(k)} - \lambda_J|^3\right), \tag{27.7}$$

当 $k \to \infty$ 时成立。式 (27.6) 两侧的 $\pm$ 不一定相同。

这里不证明“几乎所有初始向量都会收敛”的断言，只证明一旦收敛就最终三次收敛。为简单起见，假设 λ_J 是单特征值。由 (27.3)，如果 $\|v^{(k)} - q_J\| < \epsilon$ 且 ϵ 足够小，那么 Rayleigh 商给出一个满足

$$|\lambda^{(k)} - \lambda_J| = O(\epsilon^2)$$

的特征值估计。随后从 $v^{(k)}$ 和 $\lambda^{(k)}$ 出发做一步逆迭代，得到新的 $v^{(k+1)}$，于是

$$\|v^{(k+1)} - q_J\| = O\big(|\lambda^{(k)} - \lambda_J|\,\|v^{(k)} - q_J\|\big) = O(\epsilon^3).$$

O 符号中的常数在 λ_J 和 q_J 的充分小邻域内是一致的。因此，误差会按照下面的模式推进：

$$\begin{array}{cc} \|v^{(k)} - (\pm q_J)\| & |\lambda^{(k)} - \lambda_J| \\ \epsilon & O(\epsilon^2) \\ \downarrow\searrow & \\ O(\epsilon^3) & O(\epsilon^6) \\ \downarrow\searrow & \\ O(\epsilon^9) & O(\epsilon^{18}) \\ \vdots & \vdots \end{array}$$

式 (27.6)–(27.7) 就由上述一致性得到。

例 27.1（三次收敛的数值例子） 考虑对称矩阵

$$A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 4 \end{bmatrix}, \qquad v^{(0)} = \frac{(1,1,1)^T}{\sqrt{3}}.$$

对 A 使用 Rayleigh 商迭代，前三次迭代得到

$$\lambda^{(0)} = 5, \qquad \lambda^{(1)} = 5.2131\ldots, \qquad \lambda^{(2)} = 5.214319743184\ldots.$$

与 $v^{(0)}$ 最接近的特征向量对应的真实特征值为 $\lambda = 5.214319743377$。只经过三次迭代，Rayleigh 商迭代就得到了约十位有效数字；如果机器精度足够高，再进行三次迭代，准确数字大约会增加到 270 位。

运算量

最后估计上述三种迭代每一步所需的工作量。

先设 $A \in \mathbb{R}^{m\times m}$ 是满矩阵。幂迭代的每一步包含一次矩阵– 向量乘法，需要 $O(m^2)$ 次浮点运算。逆迭代的每一步需要解一个线性系统，表面上似乎需要 $O(m^3)$ 次运算；但如果事先用 LU 分解、QR 分解或其他方法处理矩阵，这个工作量可以降到 $O(m^2)$。Rayleigh 商迭代中每一步待求逆的矩阵都会改变，因此要把每步的工作量降到 $O(m^3)$ 以下并不直接。

如果 A 是三对角矩阵，情况会大大改善：现在三种迭代每一步都只需要 $O(m)$ 次浮点运算。顺便指出，对于涉及非对称矩阵的相应迭代，我们要处理的是 Hessenberg 结构而不是三对角结构，工作量会增加到 $O(m^2)$。

习题

27.1. 设 $A \in \mathbb{C}^{m\times m}$，不一定是 Hermitian 矩阵。证明：复数 $z \in \mathbb{C}$ 是 A 的某个 Rayleigh 商，当且仅当它是某个酉矩阵 Q 变换后的矩阵 Q^*AQ 的一个对角条目。也就是说，只要把坐标系正交地变换到合适的位置，Rayleigh 商正好就是矩阵的对角条目。

27.2. 仍设 $A \in \mathbb{C}^{m\times m}$ 任意。所有非零向量 $x \in \mathbb{C}^m$ 对应的 Rayleigh 商组成的集合称为 A 的值域或数值域，记为 $W(A)$，它是复平面的一个子集。

(a) 证明 $W(A)$ 包含 A 的特征值的凸包。

(b) 证明如果 A 是正规矩阵，那么 $W(A)$ 等于 A 的特征值的凸包。

27.3. 证明：对于非 Hermitian 矩阵 $A \in \mathbb{C}^{m\times m}$，Rayleigh 商 $r(x)$ 给出的特征值估计通常只有线性精度，而不是二次精度。说明这会暗示 Rayleigh 商迭代具有怎样的收敛速率。

27.4. 每个实对称方阵都可以正交对角化，而且本讲的推导在正交坐标变换下保持不变。因此，原本可以一开始就假设 A 是一个对角矩阵，并且对角条目按绝对值递减排列。在这个假设下，描述式 (27.4)、(27.5) 和算法 27.3 的具体形式。

27.5. 如正文所述，逆迭代依赖于求解一个可能极度病态的线性系统，其条件数可能达到 $\varepsilon_{\text{machine}}^{-1}$ 的量级。我们知道，一般不可能准确求解病态系统；这难道不是算法的致命缺陷吗?

证明答案是否定的：病态性并不是逆迭代的问题。设 A 是实对称矩阵，并且有一个特征值的绝对值远小于其余特征值（不妨取 $\mu = 0$）。设 v 在 A 的所有特征向量 $q_1, \ldots, q_m$ 的方向上都有分量，并且 $Aw = v$ 采用后向稳定方法求解，得到计算向量 $\widetilde{w}$。利用第 95 页的计算，证明虽然 $\widetilde{w}$ 可能与 w 相差很远，但 $\widetilde{w}/\|\widetilde{w}\|$ 不会与 $w/\|w\|$ 相差很远。

27.6. 如果 A 的两个特征值相等，图 27.1 会发生什么变化?