数值线性代数　第 28 讲：无移位 QR 算法

Lloyd N. Trefethen、David Bau III　中文阅读版

QR 算法诞生于 20 世纪 60 年代初，是数值分析中的瑰宝之一。本讲说明，在最简单的形式下，它可以看成一个稳定地计算矩阵幂 $A, A^2, A^3, \ldots$ 的 QR 分解的过程。

QR 算法

QR 算法最基本的版本简单得近乎不可思议。

算法 28.1（“纯”QR 算法）

```
A^(0) = A
for k = 1, 2, ...
      Q^(k) R^(k) = A^(k-1)        QR factorization of A^(k-1)
      A^(k) = R^(k) Q^(k)          recombine factors in reverse order
```

我们所做的全部事情，就是对当前矩阵作一次 QR 分解，把得到的因子 Q 和 R 反向相乘为 RQ，然后重复。尽管如此，在适当假设下，这个简单算法仍会收敛到矩阵 A 的 Schur 形式：一般矩阵的 Schur 形式是上三角矩阵，Hermitian 矩阵的 Schur 形式是对角矩阵。为使讨论简单，本讲继续沿用上一讲的假设：A 是实对称矩阵，特征值为实数 λ_j，特征向量 q_j 标准正交。于是，我们关心的是矩阵 $A^{(k)}$ 向对角形式的收敛。

为了让收敛到对角形式真正能够用于求特征值，所进行的操作当然必须是相似变换。这一点很容易验证：QR 算法先通过

$$R^{(k)} = (Q^{(k)})^T A^{(k-1)}$$

把 $A^{(k-1)}$ 三角化，再在右侧乘以 $Q^{(k)}$，从而得到

$$A^{(k)} = (Q^{(k)})^T A^{(k-1)} Q^{(k)}.$$

事实上，我们在第 26 讲已经见过这个相似变换：它就是“坏主意”中讨论的变换。试图用一步操作把 A 约化为三角形式时它确实是坏主意，但作为迭代的基础，它却非常强大。

和 Rayleigh 商迭代一样，实对称矩阵的 QR 算法具有三次收敛潜力。不过，要达到这种性能，必须在每一步引入移位。把算法变成实用算法还需要三项修改：

1. 开始迭代前，先把 A 约化为三对角形式（第 26 讲）。2. 每一步分解的不是 $A^{(k)}$，而是移位矩阵 $A^{(k)} - \mu^{(k)} I$，其中 $\mu^{(k)}$ 是某个特征值估计。3. 只要可能，尤其是在发现一个特征值时，就把问题“降阶”(deflate)，将 $A^{(k)}$ 拆成更小的子矩阵。

包含这些修改的 QR 算法可以概括为：

算法 28.2（“实用”QR 算法）

```
(Q^(0))^T A^(0) Q^(0) = A       A^(0) is a tridiagonalization of A
for k = 1, 2, ...
      Pick a shift mu^(k)        e.g., choose mu^(k) = A^(k-1)_{m,m}
      Q^(k)R^(k) = A^(k-1) - mu^(k)I
                                 QR factorization
      A^(k) = R^(k)Q^(k) + mu^(k)I
                                 recombine factors
      If any off-diagonal element A^(k)_{j+1,j} is close to zero,
          set A^(k)_{j,j+1} = A^(k)_{j+1,j} = 0 and obtain
          A^(k) = [ A_1  0 ; 0  A_2 ]
          then apply the QR algorithm to A_1 and A_2
```

这个带有良好移位的 QR 算法，自 20 世纪 60 年代初以来一直是计算矩阵全部特征值的标准方法。直到 20 世纪 90 年代，才出现一个竞争者：第 30 讲介绍的分治算法。三对角化已在第 26 讲讨论，移位将在下一讲讨论，而降阶在本书中不再展开。下面先把注意力限制到“纯”QR 算法，解释它如何找到特征值。

未归一化的同时迭代

我们的办法是把 QR 算法联系到另一个行为更直观的方法：同时迭代。同时迭代就是一次对多个向量应用幂迭代，也称为块幂迭代。设从一组线性无关的向量 $v_1^{(0)}, \ldots, v_n^{(0)}$ 出发。直观上，正如在适当假设下 $A^k v_1^{(0)}$ 会趋近于对应于最大模特征值的特征向量，空间

$$\operatorname{span}\{A^k v_1^{(0)}, \ldots, A^k v_n^{(0)}\}$$

也应趋近于由 A 的 n 个最大模特征值对应的特征向量 $q_1, \ldots, q_n$ 张成的空间。

用矩阵表示，定义 $m \times n$ 的初始矩阵

$$V^{(0)} = \begin{bmatrix} v_1^{(0)} & \cdots & v_n^{(0)} \end{bmatrix}. \tag{28.1}$$

定义应用 A 共 k 次后的结果

$$V^{(k)} = A^k V^{(0)} = \begin{bmatrix} v_1^{(k)} & \cdots & v_n^{(k)} \end{bmatrix}. \tag{28.2}$$

我们真正关心的是 $V^{(k)}$ 的列空间，因此对它作约化 QR 分解，为该空间提取一个条件良好的基：

$$\widehat{Q}^{(k)}\widehat{R}^{(k)} = V^{(k)}. \tag{28.3}$$

其中 $\widehat{Q}^{(k)}$ 的尺寸为 $m \times n$，$\widehat{R}^{(k)}$ 的尺寸为 $n \times n$。在适当假设下，直观上可以期待 $\widehat{Q}^{(k)}$ 的各列收敛到特征向量 $\pm q_1, \pm q_2, \ldots, \pm q_n$。

为了分析这一点，把 $v_j^{(0)}$ 和 $v_j^{(k)}$ 在 A 的特征向量基下展开：

$$v_j^{(0)} = a_{1j}q_1 + \cdots + a_{mj}q_m, \qquad v_j^{(k)} = \lambda_1^k a_{1j}q_1 + \cdots + \lambda_m^k a_{mj}q_m.$$

和上一节一样，只要满足两个条件，就能得到简单的收敛结果。第一个条件是前 $n+1$ 个特征值的模彼此满足所需的间隔：

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| > |\lambda_{n+1}| \geq |\lambda_{n+2}| \geq \cdots \geq |\lambda_m|. \tag{28.4}$$

第二个条件要求展开系数在适当意义下非奇异。令 $\widehat{Q}$ 为列向量 $q_1, \ldots, q_n$ 组成的 $m \times n$ 矩阵。注意，这里的 $\widehat{Q}$ 是特征向量矩阵，与约化 QR 分解中的 $\widehat{Q}^{(k)}$ 完全不同。我们假设

$$\widehat{Q}^T V^{(0)} \text{ 的所有顺序主子式都非奇异.} \tag{28.5}$$

这里的“所有顺序主子式”是指左上角的 $1 \times 1, 2 \times 2, \ldots, n \times n$ 方形子矩阵的行列式。条件 (28.5) 恰好等价于 $\widehat{Q}^T V^{(0)}$ 存在 LU 分解，见习题 20.1。

定理 28.1. 假设迭代 (28.1)–(28.3) 被执行，并且假设 (28.4)、(28.5) 均满足。那么当 $k \to \infty$ 时，矩阵 $\widehat{Q}^{(k)}$ 的各列线性收敛到 A 的特征向量：对 $1 \leq j \leq n$，

$$\|\widehat{q}_j^{(k)} \mp q_j\| = O(C^k), \qquad C = \max_{1 \leq j \leq n} \left| \frac{\lambda_{j+1}}{\lambda_j} \right| < 1. \tag{28.6}$$

和上一讲的定理一样，$\pm$ 表示每一步选择两个符号中的一个，然后相应的界成立。

证明 把 $\widehat{Q}$ 扩展成由 A 的特征向量组成的完整 $m \times m$ 正交矩阵 Q，令 Λ 为相应的特征值对角矩阵，于是

$$A = Q\Lambda Q^T.$$

正如 $\widehat{Q}$ 是 Q 的前 n 列，令 $\widehat{\Lambda}$ 为 Λ 的左上角 $n \times n$ 对角子矩阵。于是，当 $k \to \infty$ 时，

$$\begin{aligned} V^{(k)} = A^k V^{(0)} &= Q\Lambda^k Q^T V^{(0)} \\ &= \widehat{Q}\widehat{\Lambda}^k \widehat{Q}^T V^{(0)} + O\big(|\lambda_{n+1}|^k\big). \end{aligned}$$

如果 (28.5) 成立，那么特别地 $\widehat{Q}^T V^{(0)}$ 非奇异。将误差项右乘 $(\widehat{Q}^T V^{(0)})^{-1}\widehat{Q}^T V^{(0)}$，可以把上式改写为

$$V^{(k)} = \big(\widehat{Q}\widehat{\Lambda}^k + O(|\lambda_{n+1}|^k)\big)\widehat{Q}^T V^{(0)}.$$

由于 $\widehat{Q}^T V^{(0)}$ 非奇异，这个矩阵的列空间与

$$\widehat{Q}\widehat{\Lambda}^k + O(|\lambda_{n+1}|^k)$$

的列空间相同。由 $\widehat{Q}\widehat{\Lambda}^k$ 的形式和假设 (28.4)，可知该列空间线性收敛到 $\widehat{Q}$ 的列空间。

实际上，我们假设的不只是 $\widehat{Q}^T V^{(0)}$ 非奇异，而是它的所有顺序主子式都非奇异。因此，上面的论证也适用于 $V^{(k)}$ 和 $\widehat{Q}$ 的各个前导列子集：第一列、前两列、前三列，依此类推。对于每个这样的列空间，都得到线性收敛。再结合约化 QR 分解 (28.3) 的定义，就得到 (28.6)。 □

同时迭代

当 $k \to \infty$ 时，算法 (28.1)–(28.3) 中的向量 $v_1^{(k)}, \ldots, v_n^{(k)}$ 都会趋近于同一个主导特征向量 q_1 的倍数。因此，虽然它们张成的空间趋近于有用的空间，但这些向量会构成该空间的高度病态基。如果直接在浮点运算中执行上述同时迭代，所需信息很快会被舍入误差抹去。

补救办法很简单：每一步都正交归一化，而不是只在开始时归一化。因此不再构造上面定义的 $V^{(k)}$，而构造具有相同列空间的另一列矩阵序列 $Z^{(k)}$。

算法 28.3（同时迭代）

```
Pick Qhat^(0) in R^(m x n) with orthonormal columns.
for k = 1, 2, ...
      Z = A Qhat^(k-1)
      Qhat^(k) Rhat^(k) = Z       reduced QR factorization of Z
```

从算法形式立刻可以看出，$\widehat{Q}^{(k)}$ 和 $Z^{(k)}$ 的列空间相同，二者都等于 $A^k\widehat{Q}^{(0)}$ 的列空间。因此，从数学上说，这个新的同时迭代形式与旧形式具有相同的收敛条件。

定理 28.2. 算法 28.3 生成的矩阵 $\widehat{Q}^{(k)}$ 与定理 28.1 中迭代 (28.1)–(28.3) 生成的矩阵相同（假设初始矩阵 $\widehat{Q}^{(0)}$ 相同）。在同样的假设 (28.4)、(28.5) 下，它按照定理 28.1 所述方式收敛。

同时迭代与 QR 算法

现在可以解释 QR 算法了。它等价于对一整组 $n = m$ 个初始向量进行同时迭代，这组向量就是单位矩阵的列，即 $\widehat{Q}^{(0)} = I$。由于此时矩阵是方阵，我们处理的是完整 QR 分

解，可以去掉 $\widehat{Q}^{(k)}$ 和 $\widehat{R}^{(k)}$ 上的帽号。下文用 $Q^{(k)}$ 表示 QR 算法中的矩阵；用 $\widehat{Q}^{(k)}$ 表示同时迭代中的矩阵，以免混淆。

同时迭代（$\widehat{Q}^{(0)} = I$）由下列公式定义：

$$\widehat{Q}^{(0)} = I, \tag{28.7}$$
$$Z = A\widehat{Q}^{(k-1)}, \tag{28.8}$$
$$Z = \widehat{Q}^{(k)} R^{(k)}, \tag{28.9}$$
$$A^{(k)} = (\widehat{Q}^{(k)})^T A \widehat{Q}^{(k)}. \tag{28.10}$$

纯 QR 算法由下列公式定义，并额外定义一个 $m \times m$ 矩阵 $Q^{(k)}$：

$$A^{(0)} = A, \tag{28.11}$$
$$A^{(k-1)} = Q^{(k)} R^{(k)}, \tag{28.12}$$
$$A^{(k)} = R^{(k)} Q^{(k)}, \tag{28.13}$$
$$Q^{(k)} = Q^{(1)} Q^{(2)} \cdots Q^{(k)}. \tag{28.14}$$

此外，对两种算法都定义累计的上三角因子

$$\mathcal{R}^{(k)} = R^{(k)} R^{(k-1)} \cdots R^{(1)}. \tag{28.15}$$

这里用 $\mathcal{R}^{(k)}$ 区分累计乘积和第 k 步的因子 $R^{(k)}$。

定理 28.3. 同时迭代 (28.7)–(28.10) 与纯 QR 算法 (28.11)–(28.14) 生成相同的 $\mathcal{R}^{(k)}$、$Q^{(k)}$ 和 $A^{(k)}$。它们由 A 的 k 次幂的 QR 分解及相应的相似变换定义：

$$A^k = Q^{(k)} \mathcal{R}^{(k)}, \tag{28.16}$$

以及

$$A^{(k)} = (Q^{(k)})^T A Q^{(k)}. \tag{28.17}$$

证明 对 k 作归纳。$k = 0$ 时结论显然：两种算法的公式都给出 $A^0 = Q^{(0)} = \mathcal{R}^{(0)} = I$ 以及 $A^{(0)} = A$，所以 (28.16)、(28.17) 立即成立。

先考虑同时迭代的 $k \geq 1$。由定义 (28.10)，(28.17) 自动成立；只需验证 (28.16)：

$$\begin{aligned} A^k &= A\widehat{Q}^{(k-1)} \mathcal{R}^{(k-1)} \\ &= \widehat{Q}^{(k)} R^{(k)} \mathcal{R}^{(k-1)} \\ &= \widehat{Q}^{(k)} \mathcal{R}^{(k)}. \end{aligned}$$

第一步使用归纳假设 (28.16)，第二步使用 (28.8)、(28.9)，第三步使用 (28.15)。

再考虑 QR 算法的 $k \geq 1$。利用

$$\begin{aligned} A^k &= AQ^{(k-1)}\mathcal{R}^{(k-1)} \\ &= Q^{(k-1)}A^{(k-1)}\mathcal{R}^{(k-1)} \\ &= Q^{(k)}\mathcal{R}^{(k)}. \end{aligned}$$

第一步来自归纳假设 (28.16)，第二步来自归纳假设 (28.17)，第三步使用 (28.12)、(28.14)、(28.15)。最后，

$$A^{(k)} = (Q^{(k)})^T A^{(k-1)} Q^{(k)} = (Q^{(k)})^T A Q^{(k)},$$

第一步由 (28.12)、(28.13) 得到，第二步由归纳假设 (28.17) 得到。 □

QR 算法的收敛

现在已经具备了分析无移位 QR 算法收敛所需的全部工具。

先看定性理解。式 (28.16)、(28.17) 是关键。前者说明 QR 算法为什么能够找到特征向量：它为矩阵幂 A^k 的列空间构造标准正交基。后者说明它为什么能够找到特征值：由 (28.17)，$A^{(k)}$ 的对角条目是对应于 $Q^{(k)}$ 各列的 Rayleigh 商（见习题 27.1）。随着这些列收敛到特征向量，Rayleigh 商也收敛到相应特征值，并且根据 (27.3) 速度快一倍。同时，(28.17) 表明 $A^{(k)}$ 的非对角条目是广义 Rayleigh 商，它们分别涉及 A 的不同特征向量的左、右近似。随着这些近似收敛到不同的特征向量，它们必须变得正交，因此 $A^{(k)}$ 的非对角条目必然趋于零。

需要特别强调，式 (28.16)、(28.17) 对理解无移位 QR 算法极其基础。记住它们，几乎所有重要结论都可以由此推出。

定量地说，由定理 28.2 可得以下结果。

定理 28.4. 设纯 QR 算法（算法 28.1）作用于实对称矩阵 A。假设其特征值满足

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_m|,$$

且对应的特征向量矩阵 Q 的所有顺序主子式都非奇异。那么当 $k \to \infty$ 时，$A^{(k)}$ 以线性速率、收敛常数

$$\max_{1 \leq j < m} \left| \frac{\lambda_{j+1}}{\lambda_j} \right|$$

收敛到 $\operatorname{diag}(\lambda_1, \ldots, \lambda_m)$；对 $Q^{(k)}$ 的各列作必要的符号调整后，$Q^{(k)}$ 也以相同速率收敛到 Q。

习题

28.1. 把无移位 QR 算法应用于正交矩阵会发生什么？先找出答案，再解释它与定理 28.4 的关系。

28.2. 如果 QR 算法的每一步不能保持三对角结构，那么事先约化为三对角形式就几乎没有用处。幸运的是，它确实保持这一结构。

(a) 对三对角矩阵 A 的 QR 分解 $A = QR$，R 的哪些条目一般非零？Q 的哪些条目一般非零？（实际计算中不显式构造 Q。）

(b) 证明形成乘积 RQ 后会恢复三对角结构。

(c) 说明如何在三对角矩阵的 QR 分解中使用 Givens 旋转或 2×2 Householder 反射，从而把运算量大幅降到满矩阵所需运算量以下。

28.3. 实对称矩阵 A 有一个重数为 8 的特征值 1，而其余特征值的绝对值都不超过 0.1。描述一个求出对应于主导特征值的 8 维特征子空间标准正交基的算法。

28.4. 考虑算法 28.1 作用于三对角实对称矩阵 $A \in \mathbb{R}^{m \times m}$ 的一步。

(a) 如果只需要特征值，那么第 k 步只需要 $A^{(k)}$，不需要 $Q^{(k)}$。使用本书介绍的标准方法，确定从 $A^{(k-1)}$ 得到 $A^{(k)}$ 需要多少次浮点运算。

(b) 如果需要全部特征向量，还必须累积矩阵 $Q^{(k)} = Q^{(1)}Q^{(2)} \cdots Q^{(k)}$。确定从第 $k-1$ 步到第 k 步现在需要多少次浮点运算。