数值线性代数　第 38 讲：共轭梯度法

Lloyd N. Trefethen、David Bau III
中文阅读版

原书页码：293–302；　**目标 PDF 页码**：308–317。

共轭梯度（conjugate gradient，CG）迭代是“最初的”Krylov 子空间迭代，也是这类方法中最著名、最重要的科学计算方法之一。它由 Hestenes 和 Stiefel 于 1952 年发现；当特征值分布良好时，它能够极快地求解对称正定方程组。

最小化残量的 2-范数

和前两讲一样，设 $A \in \mathbb{R}^{m\times m}$ 为实对称矩阵。我们希望求解非奇异方程组

$$Ax = b,$$

其精确解记为 $x_* = A^{-1}b$。令 $\mathcal{K}_n$ 表示由 b 生成的第 n 个 Krylov 子空间：

$$\mathcal{K}_n = \operatorname{span}\{b, Ab, \ldots, A^{n-1}b\}. \tag{38.1}$$

一种基于这个 Krylov 子空间的方法是 GMRES。按照第 35 讲的描述，在第 n 步，GMRES 选择 $x_n \in \mathcal{K}_n$，使残量 $r_n = b - Ax_n$ 的 2-范数 $\|r_n\|_2$ 最小。

不过，通常的 GMRES 算法在最小化 $\|r_n\|_2$ 时做了超过必要的工作。由于 A 是对称的，可以使用基于三项递推而不是 $(n+1)$ 项递推的更快算法。其中一种方法称为共轭残量法（conjugate residuals）或 MINRES（minimal residuals，最小残量法）。这些方法如果要同时适用于正定和不定矩阵，会带来一些额外复杂性；下面直接转向更简单、也更重要的正定情形。

最小化误差的 A-范数

现在进一步假设 A 不仅实对称，而且正定。正如第 23 讲所述，这意味着 A 的全部特征值为正，等价地，对任意非零 $x \in \mathbb{R}^m$ 都有 $x^TAx > 0$。在这一假设下，定义

$$\|x\|_A = \sqrt{x^TAx}. \tag{38.2}$$

它是 $\mathbb{R}^m$ 上的一个范数，可以直接由范数定义（3.1）验证。它称为 A-范数。如果 $W^TW = A$（例如 W 是 A 的 Cholesky 因子），那么它也就是 $\|Wx\|_2$。

我们关心的向量是第 n 步的误差 $e_n = x_* - x_n$。共轭梯度迭代可以描述为：通过一组递推公式，生成唯一的序列 $\{x_n \in \mathcal{K}_n\}$，使得每一步的 $\|e_n\|_A$ 都最小。

共轭梯度迭代

下面给出 Hestenes 和 Stiefel 使之闻名的迭代。先不解释动机，之后先推导正交性，再把这些性质转化为最优性结论；最后从非线性优化的角度解释动机。

算法 38.1　共轭梯度（CG）迭代

$$x_0 = 0, \qquad r_0 \leftarrow b, \qquad p_0 = r_0.$$

对 $n = 1, 2, 3, \ldots$：

$$\alpha_n = \frac{r_{n-1}^T r_{n-1}}{p_{n-1}^T A p_{n-1}} \qquad \text{步长,}$$

$$x_n = x_{n-1} + \alpha_n p_{n-1} \qquad \text{近似解,}$$

$$r_n = r_{n-1} - \alpha_n A p_{n-1} \qquad \text{残量,}$$

$$\beta_n = \frac{r_n^T r_n}{r_{n-1}^T r_{n-1}} \qquad \text{本步的改进系数,}$$

$$p_n = r_n + \beta_n p_{n-1} \qquad \text{搜索方向.}$$

在分析这些公式的数学性质之前，先看它们在计算上的含义。CG 迭代非常简单，用几行 MATLAB 就可以编程实现。它只处理 m-维向量，而不需要逐个处理矩阵或向量条目，因此甚至比带选主元的高斯消去还简单。唯一没有在这里讨论的实际问题，是如何选择收敛判据。

每一步 CG 迭代包含若干向量运算和一次矩阵–向量乘法；算法列表中 Ap_{n-1} 出现两次，但只需计算一次。如果 A 稠密且没有结构，这次矩阵–向量乘法占主导地位，每步约需 $2m^2$ 次浮点运算。如果 A 稀疏，或存在其他可利用的结构，使得 Ap_{n-1} 只需 $O(m)$ 次运算，那么每步的运算量也可以低至 $O(m)$。

从算法的五行公式可以推出下面的性质。和本书中没有明确提及舍入误差的定理一样，下面的定理假定精确算术。存在舍入误差时，这些性质会失效，而 CG 仍然能保持惊人性能的原因也会变成一个微妙问题。

定理 38.1. 将算法 38.1 应用于对称正定问题 $Ax = b$。只要迭代尚未收敛（即 $r_{n-1} \neq 0$），算法就不会发生除以零，并且有以下子空间恒等式：

$$\begin{aligned}\mathcal{K}_n &= \operatorname{span}\{x_1, x_2, \ldots, x_n\} \\ &= \operatorname{span}\{p_0, p_1, \ldots, p_{n-1}\} \\ &= \operatorname{span}\{r_0, r_1, \ldots, r_{n-1}\} \\ &= \operatorname{span}\{b, Ab, \ldots, A^{n-1}b\}.\end{aligned} \tag{38.3}$$

此外，残量彼此正交：

$$r_n^T r_j = 0 \qquad (j < n), \tag{38.4}$$

搜索方向是“A-共轭”的：

$$p_n^T A p_j = 0 \qquad (j < n). \tag{38.5}$$

证明。证明按 n 归纳；这里给出非正式的提纲。由初始猜测 $x_0 = 0$ 以及 $x_n = x_{n-1} + \alpha_n p_{n-1}$，归纳可知 x_n 属于 $\operatorname{span}\{p_0, \ldots, p_{n-1}\}$。由 $p_n = r_n + \beta_n p_{n-1}$，这个空间也等于 $\operatorname{span}\{r_0, \ldots, r_{n-1}\}$。最后，由 $r_n = r_{n-1} - \alpha_n A p_{n-1}$，它又等于 $\operatorname{span}\{b, Ab, \ldots, A^{n-1}b\}$，于是得到式（38.3）。

为了证明式（38.4），使用 $r_n = r_{n-1} - \alpha_n A p_{n-1}$ 以及 $(Ap_{n-1})^T = p_{n-1}^T A$，得到

$$r_n^T r_j = r_{n-1}^T r_j - \alpha_n p_{n-1}^T A r_j.$$

若 $j < n-1$，右侧两项都由归纳假设为零。若 $j = n-1$，只要取

$$\alpha_n = \frac{r_{n-1}^T r_{n-1}}{p_{n-1}^T A r_{n-1}},$$

右侧差值就为零。这与算法 38.1 中 $\alpha_n = (r_{n-1}^T r_{n-1})/(p_{n-1}^T A p_{n-1})$ 相同，只是把分母 $p_{n-1}^T A p_{n-1}$ 换成了 $p_{n-1}^T A r_{n-1}$。由于 p_{n-1} 与 r_{n-1} 相差一个属于 $\mathcal{K}_{n-2}$ 的向量，这一替换对分母的改变是 $\beta_{n-1} p_{n-1}^T A p_{n-2}$，由归纳假设为零。

为了证明式（38.5），使用 $p_n = r_n + \beta_n p_{n-1}$，得到

$$p_n^T A p_j = r_n^T A p_j + \beta_n p_{n-1}^T A p_j.$$

若 $j < n-1$，归纳可知右侧两项再次都为零（此时式（38.4）已经对第 n 步成立）。若 $j = n-1$，只要

$$\beta_n = -\frac{r_n^T A p_{n-1}}{p_{n-1}^T A p_{n-1}}$$

即可使右侧和为零。利用 $r_n = r_{n-1} - \alpha_n A p_{n-1}$，这等价于

$$\beta_n = \frac{-\alpha_n r_{n-1}^T A p_{n-1}}{\alpha_n p_{n-1}^T A p_{n-1}}.$$

这与算法 38.1 中 $\beta_n = (r_n^T r_n)/(r_{n-1}^T r_{n-1})$ 相同，只是把分子 $r_n^T r_n$ 换成 $r_n^T(-\alpha_n A p_{n-1})$，把分母 $r_{n-1}^T r_{n-1}$ 换成 $p_{n-1}^T(\alpha_n A p_{n-1})$。结合归纳假设以及算法 38.1 的第 3、5 行，可以直接验证这些替换不改变结果。证毕。

CG 的最优性

推导式（38.4）和（38.5）时，真正困难的工作已经完成。现在只需确认 CG 在每一步确实最小化 $\|e\|_A$。

定理 38.2. 将 CG 迭代应用于对称正定问题 $Ax = b$。如果迭代尚未收敛（即 $r_{n-1} \neq 0$），那么 x_n 是 $\mathcal{K}_n$ 中使 $\|e_n\|_A$ 最小的唯一点。收敛是单调的：

$$\|e_n\|_A \leq \|e_{n-1}\|_A, \tag{38.6}$$

并且对某个 $n \leq m$ 有 $e_n = 0$。

证明。 由定理 38.1，$x_n \in \mathcal{K}_n$。为了证明它是 $\mathcal{K}_n$ 中唯一的最小点，任取

$$\widetilde{x} = x_n - \Delta x \in \mathcal{K}_n, \qquad e = x_* - \widetilde{x} = e_n + \Delta x.$$

于是

$$\begin{aligned} \|e\|_A^2 &= (e_n + \Delta x)^T A (e_n + \Delta x) \\ &= e_n^T A e_n + (\Delta x)^T A (\Delta x) + 2 e_n^T A (\Delta x). \end{aligned}$$

最后一项是 $2r_n^T(\Delta x)$，即 r_n 与 $\mathcal{K}_n$ 中向量的内积；根据定理 38.1，它为零。因此

$$\|e\|_A^2 = e_n^T A e_n + (\Delta x)^T A (\Delta x).$$

只有第二项依赖于 Δx。又由于 A 正定，这一项非负，且当且仅当 $\Delta x = 0$ 时取到 0，即 $\widetilde{x} = x_n$。所以 $\|e\|_A$ 在且仅在 $\widetilde{x} = x_n$ 时达到最小值。

定理剩余的结论也随之得到。式（38.6）的单调性来自 $\mathcal{K}_n \subseteq \mathcal{K}_{n+1}$；只要尚未收敛，$\mathcal{K}_n$ 是 $\mathbb{R}^m$ 中维数为 n 的子空间，因此至多 m 步必然收敛。证毕。

在浮点算术中，“至多 m 步收敛”的保证是空的。对任意实机上的矩阵 A，即使 $n = m$，也不一定观察到 $\|e_n\|_A$ 有决定性的下降。不过，实践中使用 CG 的对象不是任意矩阵，而是谱性质足够良好的矩阵；这可能得益于预处理，使得在 $n \ll m$ 时就达到所需精度（见第 32 讲）。因此，$n = m$ 时的理论精确收敛与科学计算中实际使用 CG 的目的并不直接相关。

把 CG 看成优化算法

我们刚才证明了 CG 的一个最优性：第 n 步在所有 $x \in \mathcal{K}_n$ 中最小化 $\|e_n\|_A$。事实上，从“步长”和“搜索方向”这些术语就可以看出，它可以解释为在 $\mathbb{R}^m$ 上最小化一个非线性函

数的标准迭代算法。迭代的核心公式是

$$x_n = x_{n-1} + \alpha_n p_{n-1}.$$

这正是优化中的熟悉形式：沿搜索方向 p_{n-1} 移动步长 α_n，把当前近似 x_{n-1} 更新为 x_n。连续执行这样的步骤，就试图找到某个非线性函数的最小点。

是哪一个函数？按照定理 38.2，答案似乎应当是 $\|e\|_A$，或等价地 $\|e\|_A^2$。然而，虽然 $\|e\|_A^2$ 确实是 x 的函数，如果不知道精确解 x_*，就无法计算它。把 CG 解释成优化一个无法计算的函数，显然不够“标准”。

另一方面，给定 A、b 和 $x \in \mathbb{R}^m$，下列量是可以直接计算的：

$$\varphi(x) = \frac{1}{2} x^T A x - x^T b. \tag{38.7}$$

直接计算可得

$$\begin{aligned} \|e_n\|_A^2 = e_n^T A e_n &= (x_* - x_n)^T A (x_* - x_n) \\ &= x_*^T A x_* - 2 x_n^T A x_* + x_n^T A x_n \\ &= x_*^T A x_* - 2 x_n^T b + x_n^T A x_n \\ &= 2\varphi(x_n) + \text{常数}. \end{aligned}$$

所以 $\varphi(x)$ 与 $\|e\|_A^2$ 只相差因子 2 和未知常数 $x_*^T b$。和 $\|e\|_A$ 一样，它的唯一最小点也是 $x = x_*$。

因此，CG 可以解释为在 $\mathbb{R}^m$ 上最小化二次函数 $\varphi(x)$ 的迭代过程。每一步计算 $x_n = x_{n-1} + \alpha_n p_{n-1}$，使 $\varphi(x)$ 在一维空间 $x_{n-1} + \operatorname{span}\{p_{n-1}\}$ 上达到最小。（容易验证，算法中的 $\alpha_n = (r_{n-1}^T r_{n-1})/(p_{n-1}^T A p_{n-1})$ 在所有步长中使 φ 最小。）CG 的特别之处在于搜索方向 p_{n-1}：在该方向上最小化 φ，实际上就等价于在整个 $\mathcal{K}_n$ 上最小化它。

CG 求解 $Ax = b$ 与 Lanczos 迭代求特征值之间存在紧密类比。第 27 讲指出，A 的特征值是 $\mathbb{R}^m$ 上 Rayleigh 商

$$r(x) = \frac{x^T A x}{x^T x}$$

的驻值。习题 36.1 指出，Lanczos 第 n 步的特征值估计（Ritz 值）正是把 x 限制在 Krylov 子空间 $\mathcal{K}_n$ 后，这个函数的驻值。这与我们刚刚证明的结论完全平行：$Ax = b$ 的解 x_* 是 $\mathbb{R}^m$ 上标量函数 $\varphi(x)$ 的最小点，而 CG 迭代 x_n 是把 x 限制在 $\mathcal{K}_n$ 后同一函数的最小点。

CG 与多项式逼近

前四讲反复出现的主题，是 Krylov 子空间迭代与矩阵多项式之间的联系。Arnoldi 和 Lanczos 迭代解决 Arnoldi/Lanczos 逼近问题（34.3），GMRES 解决 GMRES 逼近问题 (35.10)。对 CG 来说，相应的逼近问题涉及误差的 A-范数：

CG 逼近问题。寻找 $p_n \in \mathcal{P}_n$，使得

$$\|p_n(A)e_0\|_A = \min . \tag{38.8}$$

这里 e_0 是初始误差，即 $e_0 = x_* - x_0 = x_*$；$\mathcal{P}_n$ 与式（35.7）中的定义相同，是满足 $p(0) = 1$ 且次数不超过 n 的多项式集合。由定理 38.2 可以得到下面的收敛定理。

定理 38.3. 如果 CG 在第 n 步之前尚未收敛（即 $r_{n-1} \neq 0$），那么式（38.8）有唯一解 $p_n \in \mathcal{P}_n$，并且第 n 步误差为 $e_n = p_n(A)e_0$。因此

$$\frac{\|e_n\|_A}{\|e_0\|_A} = \inf_{p\in\mathcal{P}_n} \frac{\|p(A)e_0\|_A}{\|e_0\|_A} \leq \inf_{p\in\mathcal{P}_n} \max_{\lambda\in\Lambda(A)} |p(\lambda)|, \tag{38.9}$$

其中 $\Lambda(A)$ 表示 A 的谱。

证明。由定理 38.1，存在某个 $p \in \mathcal{P}_n$ 使 $e_n = p(A)e_0$。式（38.9）中的等号由此事实和定理 38.2 得到。对于不等号，设 $e_0 = \sum_{j=1}^m a_j v_j$，其中 v_j 是 A 的一组正交归一特征向量，对应特征值 λ_j。则

$$p(A)e_0 = \sum_{j=1}^m a_j p(\lambda_j) v_j,$$

从而

$$\|e_0\|_A^2 = \sum_{j=1}^m a_j^2 \lambda_j, \qquad \|p(A)e_0\|_A^2 = \sum_{j=1}^m a_j^2 \lambda_j p(\lambda_j)^2.$$

因此

$$\frac{\|p(A)e_0\|_A^2}{\|e_0\|_A^2} \leq \max_{\lambda\in\Lambda(A)} |p(\lambda)|^2,$$

这就推出了式（38.9）中的不等式。证毕。

收敛速率

定理 38.3 表明，CG 的收敛速率由 A 的谱位置决定。所谓“好”的谱，是指存在 $p_n \in \mathcal{P}_n$，使其在谱上很小，并且随 n 增大而快速变小。粗略地说，这可能来自两个原因之一，或者二者兼有：特征值聚集成小簇，或者它们整体上与原点保持良好的相对分离。定理 38.3 的两个最著名推论分别讨论这两种情形的极端版本。

先假设特征值完全聚集，但不对这些簇的位置作任何假设。

定理 38.4. 如果 A 只有 n 个不同的特征值，那么 CG 至多经过 n 步就收敛。

证明。这是式（38.9）的直接推论：存在

$$p(x) = \prod_{j=1}^n \left(1 - \frac{x}{\lambda_j}\right) \in \mathcal{P}_n,$$

它在指定的 n 个点 $\{\lambda_j\}$ 上全为零。证毕。

在另一种极端情形下，假设我们对特征值是否聚集一无所知，只知道它们到原点的距离最多相差一个因子 $\kappa > 1$。换言之，只知道 A 的 2-范数条件数

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}},$$

其中 $\lambda_{\max}$、$\lambda_{\min}$ 是 A 的最大和最小特征值。

定理 38.5. 设 CG 应用于对称正定问题 $Ax = b$，且 A 的 2-范数条件数为 κ。则误差的 A-范数满足

$$\frac{\|e_n\|_A}{\|e_0\|_A} \le 2\left[\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^n + \left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^{-n}\right]^{-1} \le 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^n. \tag{38.10}$$

证明。根据定理 38.3，只需寻找一个 $p \in \mathcal{P}_n$，使它在 $[\lambda_{\min}, \lambda_{\max}]$ 上的最大值达到式（38.10）中间的表达式。取缩放平移后的 Chebyshev 多项式

$$p(x) = \frac{T_n\!\left(\gamma - \dfrac{2x}{\lambda_{\max}-\lambda_{\min}}\right)}{T_n(\gamma)}, \qquad \gamma = \frac{\lambda_{\max}+\lambda_{\min}}{\lambda_{\max}-\lambda_{\min}} = \frac{\kappa+1}{\kappa-1}.$$

当 $x \in [\lambda_{\min}, \lambda_{\max}]$ 时，$p(x)$ 分子中的 Chebyshev 多项式自变量位于 $[-1, 1]$，所以分子绝对值不超过 1。因此只需证明

$$T_n(\gamma) = T_n\!\left(\frac{\kappa+1}{\kappa-1}\right) = \frac{1}{2}\left[\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^n + \left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^{-n}\right]. \tag{38.11}$$

令

$$x = \frac{1}{2}(z + z^{-1}), \qquad T_n(x) = \frac{1}{2}(z^n + z^{-n}),$$

这是 Chebyshev 多项式的标准表示。若 $\frac{\kappa+1}{\kappa-1} = \frac{1}{2}(z + z^{-1})$，则 z 满足二次方程

$$\frac{1}{2}z^2 - \frac{\kappa+1}{\kappa-1}z + \frac{1}{2} = 0.$$

取大于 1 的根，有

$$\begin{aligned} z &= \frac{\kappa+1}{\kappa-1} + \sqrt{\left(\frac{\kappa+1}{\kappa-1}\right)^2 - 1} \\ &= \frac{\kappa+1+\sqrt{(\kappa+1)^2-(\kappa-1)^2}}{\kappa-1} \\ &= \frac{\kappa+1+\sqrt{4\kappa}}{\kappa-1} = \frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}. \end{aligned}$$

于是 $T_n(\gamma) = \frac{1}{2}(z^n + z^{-n})$，即式（38.11）。证毕。

定理 38.5 是关于 CG 收敛的最著名结果。由于

$$\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \sim 1 - \frac{2}{\sqrt{\kappa}} \qquad (\kappa \to \infty),$$

它表明：当 κ 较大但还没有大到不可接受时，达到给定容差通常只需 $O(\sqrt{\kappa})$ 次迭代。不过这只是上界；对特殊右端项（不太常见）或聚集谱（更常见），收敛可能更快。

例

考虑如下构造的 500×500 稀疏矩阵 A，作为 CG 收敛的例子。先在每个对角位置放置 1，在每个非对角位置放置一个服从 $[-1, 1]$ 均匀分布的随机数，并保持对称性 $A = A^T$。然后对每个满足 $|a_{ij}| > \tau$ 的非对角元素，将其替换为 0，其中 τ 是参数。当 τ 接近 0 时，所得矩阵是条件良好的正定矩阵，非零元密度约为 τ。随着 τ 增大，条件数和非零结构都会恶化。

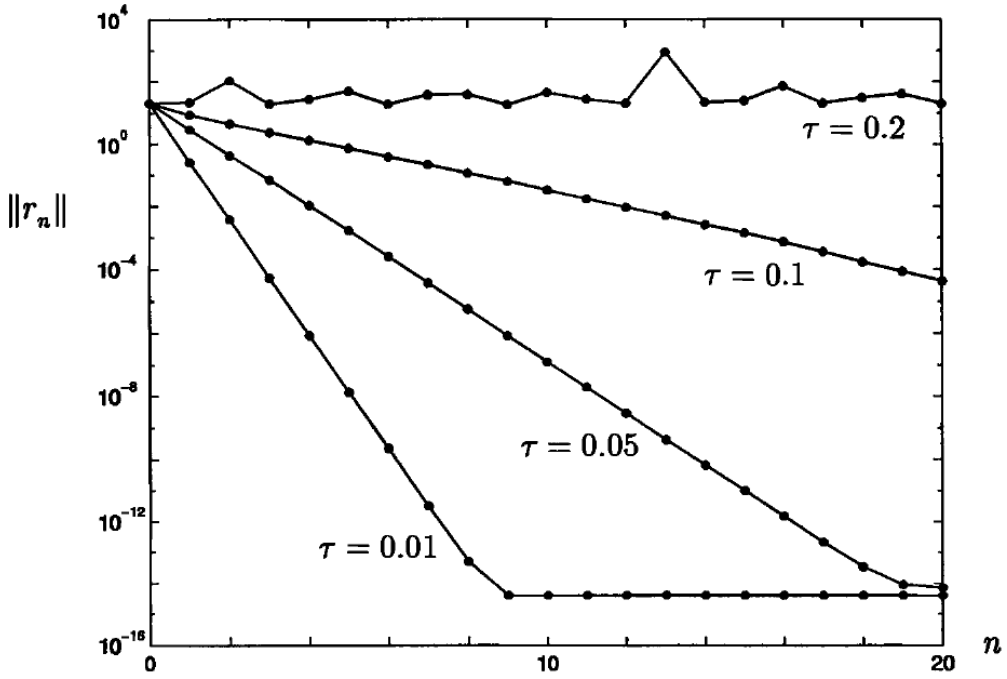


图 38.1. 文中所述 500×500 稀疏矩阵的 CG 收敛曲线。$\tau = 0.01$ 时，CG 比 Cholesky 分解快约 700 倍；$\tau = 0.2$ 时，矩阵不是正定的，因此没有收敛。

图 38.1 给出了这类矩阵在 CG 迭代前 20 步中的收敛曲线；右端项 b 取为随机向量。各参数的数值表现如下：

- $\tau = 0.01$：A 有 3092 个非零元，$\kappa \approx 1.06$；9 步达到机器精度，约需 6×10^4 次浮点运算。
- $\tau = 0.05$：有 13062 个非零元，$\kappa \approx 1.83$；19 步收敛，约需 5×10^5 次浮点运算。
- $\tau = 0.1$：有 25526 个非零元，$\kappa \approx 10.3$；20 步后只有约 5 位数字收敛，约需 10^6 次浮点运算。

- $\tau = 0.2$：有 50834 个非零元，完全没有收敛。此时最低特征值为负，A 不再正定，使用 CG 不合适。（CG 有时也能在不定矩阵上成功，但这里的矩阵不仅不定，而且病态。）

注意，$\tau = 0.01$ 的曲线与图 32.1 的理想示意图非常接近。在这个例子中，6×10^4 次浮点运算比 Cholesky 分解（式（23.4））快约 700 倍。遗憾的是，即使尽力寻找良好的预条件器，实际问题中的矩阵也不一定拥有这样规整的谱。

习题

38.1. 根据正文报告的条件数 κ，确定定理 38.5 对图 38.1 中 $\tau = 0.01, 0.05, 0.1$ 三个矩阵所预测的收敛速率。在图 38.1 的副本上画出相应直线，说明这些预测与实际收敛速率有多接近。

38.2. 设 A 是一个实对称 805×805 矩阵，其特征值为 $1.00, 1.01, 1.02, \ldots, 8.98, 8.99, 9.00$，此外还有 $10, 12, 16, 24$。为了确保把初始误差 $\|e_0\|_A$ 降低 10^6 倍，需要进行多少步共轭梯度迭代？

38.3. CG 应用于对称正定矩阵 A，得到 $\|e_0\|_A = 1$、$\|e_1\|_A = 2 \times 10^{-16}$。仅根据这些数据：

(a) 能对 $\kappa(A)$ 给出什么上界？

(b) 能对 $\|e_{20}\|_A$ 给出什么上界？

38.4. 设 A 是稠密的对称正定 1000×1000 矩阵，且 $\kappa(A) = 100$。粗略估计为了以十位数字的精度求解 $Ax = b$，以下方法分别需要多少次浮点运算：(a) Cholesky 分解；(b) 使用最优参数 α 的 Richardson 迭代（习题 35.3）；(c) CG。

38.5. 我们把 CG 描述成对式（38.7）的函数 $\varphi(x)$ 做迭代最小化。另一种最小化同一函数的方法是通常更慢的最速下降法。

(a) 推导 $\nabla\varphi(x) = Ax - b = -r$。因此，最速下降迭代相当于在算法 38.1 中取 $p_n = r_n$，而不是 $p_n = r_n + \beta_n p_{n-1}$。

(b) 确定最速下降迭代的最优步长 α_n 公式。

(c) 写出完整的最速下降迭代。主循环内共有三个操作。

38.6. 设 A 是一个 100×100 的对称三对角矩阵，对角元为 $1, 2, \ldots, 100$，次对角线和超对角线上的元素为 1，并令 $b = (1, 1, \ldots, 1)^T$。编写程序，分别进行 100 步 CG 迭代和最速下降迭代，近似求解 $Ax = b$。绘制四条曲线：

(a) CG 的计算残量范数 $\|r_n\|_2$；

(b) CG 的实际残量范数 $\|b - Ax_n\|_2$；

(c) 最速下降法的残量范数 $\|r_n\|_2$；

(d) 定理 38.5 的估计

$$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^n.$$

评论你的结果。