# 数值线性代数　第 39 讲：双正交化方法

Lloyd N. Trefethen、David Bau III

中文阅读版

**原书页码**：303–312；　**目标 PDF 页码**：318–327。

对于非对称（更一般地，非 Hermitian）线性系统，并不是所有 Krylov 子空间迭代都必须使用长度不断增长、代价不断增加的递推。基于三项递推的方法也已经被构造出来，而且它们是目前最有力的非对称迭代方法。至少对其中一部分方法而言，需要付出的代价是：必须同时处理两个 Krylov 子空间，而不是一个；这两个子空间分别由 $A^*$ 和 $A$ 的乘法生成。

## 我们目前所处的位置

在第 31 讲（原书第 245 页）我们给出过 Krylov 子空间矩阵迭代的分类：

| | $Ax = b$ | $Ax = \lambda x$ |
|---|---|---|
| $A = A^*$ | CG | Lanczos |
| $A \neq A^*$ | GMRES、CGN、BCG 等 | Arnoldi |

其中三个方框的讨论已经完成；对于左下角的第四个位置 GMRES，我们也已经在前面讲过。本讲先用很短的篇幅介绍 CGN，再转向本讲的主要主题：右下角“BCG 等”所代表的双正交化方法。图 39.1 给出了这些方法之间的结构关系。

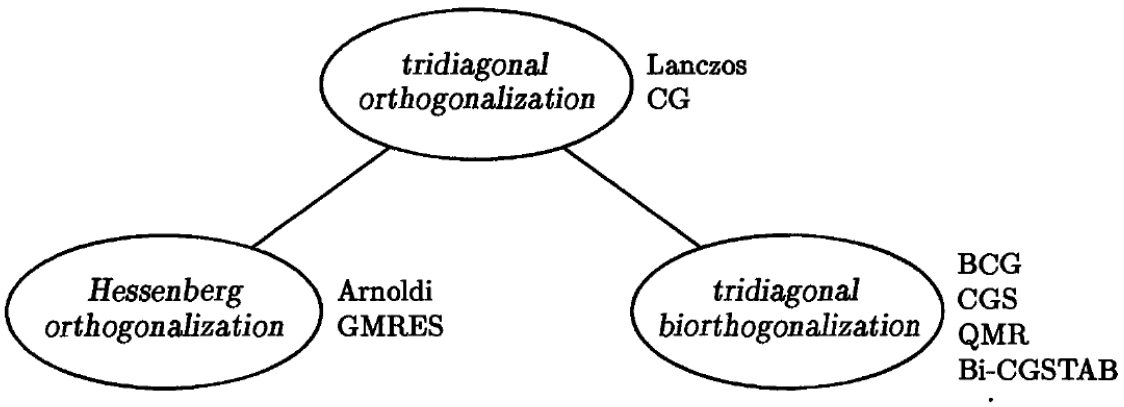



图 39.1. Krylov 子空间迭代的分类。若矩阵是 Hermitian 的（上方一行），可以用三项递推关系把它正交化为三对角矩阵；若不是 Hermitian 的，就必须在三对角结构与正交性之间放弃其中一个。图中文字保留原图标注，便于和原书核对。

# CGN：把 CG 应用于正规方程

设 $A \in \mathbb{C}^{m\times m}$ 非奇异，但不一定是 Hermitian 矩阵。于是对任意 $b \in \mathbb{C}^m$，方程 $Ax = b$ 都是一个非奇异的方阵系统。求解这类系统的最简单方法之一，是把 CG 迭代应用于正规方程

$$A^*Ax = A^*b. \tag{39.1}$$

实际计算时不会显式形成 $A^*A$，因为这样需要 $m^3$ 量级的浮点运算。取而代之，每次计算矩阵–向量乘积 $A^*Av$ 时，分两步先算 $Av$，再算 $A^*(Av)$。由于 $A$ 非奇异，$A^*A$ 是 Hermitian 正定矩阵；若 $A$ 为实矩阵，则它是对称正定矩阵。因此第 38 讲中的定理都可以直接使用：只要 $A^*A$ 的特征值分布良好，就可以期待快速收敛。这一方法称为 CGN（也称 CGNR），大意是“应用于正规方程的 CG”。

由于 CG 的行为已经分析过，理解 CGN 不需要新的理论。若像算法 38.1 那样取初始猜测 $x_0 = 0$，则由定理 38.1，后续迭代属于由 $A^*A$ 生成的 Krylov 子空间：

$$x_n \in \operatorname{span}\big\{A^*b,\, (A^*A)A^*b,\, \ldots,\, (A^*A)^{n-1}A^*b\big\}. \tag{39.2}$$

定理 38.2 告诉我们，在这个子空间上，误差的 $A^*A$-范数在每一步都被最小化。如果 $e_n = x_* - x_n$、$r_n = b - Ax_n$，那么

$$\|e_n\|_{A^*A}^2 = e_n^*A^*Ae_n = \|Ae_n\|_2^2 = \|r_n\|_2^2.$$

所以这也就是说，残量的 2-范数被最小化：

$$\|r_n\|_2 = \text{最小值}. \tag{39.3}$$

因此，CGN 和 GMRES 一样，都是最小残量方法。不过，它们所使用的 Krylov 子空间分别是第 33 讲的式（33.5）与式（39.2），两者不同，所以这两个方法绝不等价。

根据定理 38.3，CGN 的收敛由 $A^*A$ 的特征值控制，而这些特征值正好是 $A$ 奇异值的平方。因此，CGN 的收敛由 $A$ 的奇异值决定，原则上与 $A$ 的特征值无关。遗憾的是，这里出现了平方。如果 $A$ 的条件数为 $\kappa$，则 $A^*A$ 的条件数为 $\kappa^2$；将第 38 讲的估计改写为 CGN 的形式，得到

$$\frac{\|r_n\|_2}{\|r_0\|_2} \le 2\left(\frac{\kappa-1}{\kappa+1}\right)^n. \tag{39.4}$$

当 $\kappa$ 很大时，这比第 38 讲的估计糟糕得多：为了达到固定精度，所需迭代步数是 $O(\kappa)$，而不是 $O(\sqrt{\kappa})$。这种“条件数平方化”使 CGN 名声不佳，总体而言这或许是有理由的。不过，对某些问题，CGN 仍然会远胜其他方法，因为其他方法的收敛依赖特征值，而不是奇异值。只要构造一个奇异值表现良好、特征值表现很差的矩阵即可，例如一个条件良好、但谱在复平面原点周围包围原点的矩阵。

一个极端例子是如下 $m \times m$ 循环矩阵：

$$A = \begin{bmatrix} 0 & 1 & & & \\ & 0 & 1 & & \\ & & 0 & \ddots & \\ & & & \ddots & 1 \\ 1 & & & & 0 \end{bmatrix}. \tag{39.5}$$

这个矩阵的所有奇异值都等于 1，但特征值是 $m$ 次单位根。对于一般的右端项 $b$，GMRES 需要 $m$ 步才能收敛，而 CGN 一步就收敛（见习题 39.1）。

CGN 的另一个优点是：因为它建立在正规方程上，所以可以不加修改地应用于最小二乘问题，此时 $A$ 不再要求是方阵（参见算法 11.1）。另一种做法是使用习题 19.1 中的块系统（19.4）。

## 三对角双正交化

正如第 36 讲所见，Lanczos 迭代是一个**三对角正交化**过程。如果在精确算术下完整运行 $m$ 步，它会把 Hermitian 矩阵酉相似约化为三对角形式：

$$A = QTQ^*.$$

如果 $A$ 不是 Hermitian 的，一般不可能得到这样的约化；我们必须放弃酉变换，或者放弃最终的三对角形式。Arnoldi 迭代是 Hessenberg 正交化过程，它选择放弃后者。完整运行 $m$ 步时，它把任意方阵酉相似约化为 Hessenberg 形式：

$$A = QHQ^*.$$

双正交化方法采取相反的选择：坚持得到三对角矩阵，但放弃酉变换。于是得到 **三对角双正交化**：

$$A = VTV^{-1},$$

其中 $V$ 非奇异，但一般不是酉矩阵（见图 39.1）。对上式取伴随可得等价关系

$$A^* = V^{-*}T^*V^*, \qquad V^{-*} = (V^*)^{-1} = (V^{-1})^*.$$

“双正交”一词指的是：虽然 $V$ 的列向量彼此不一定正交，但它们与 $V^{-*}$ 的列向量正交。这直接来自

$$(V^{-*})^*V = V^{-1}V = I.$$

为了把这个想法变成迭代算法，考虑 $n < m$ 的情形。设 $V$ 是满足 $A = VTV^{-1}$ 的非奇异矩阵，且 $T$ 为三对角矩阵；令 $W = V^{-*}$。记 $v_j$ 和 $w_j$ 分别为 $V$ 与 $W$ 的第 $j$ 列。它们满足双正交关系

$$w_i^* v_j = \delta_{ij}, \tag{39.6}$$

其中 $\delta_{ij}$ 是 Kronecker $\delta$ 函数。对 $1 \le n \le m$，定义 $m \times n$ 矩阵

$$V_n = \begin{bmatrix} v_1 & \cdots & v_n \end{bmatrix}, \qquad W_n = \begin{bmatrix} w_1 & \cdots & w_n \end{bmatrix}. \tag{39.7}$$

双正交条件的矩阵形式为

$$W_n^* V_n = V_n^* W_n = I_n.$$

这里 $I_n$ 是 $n$ 阶单位矩阵。

## 关键矩阵关系与三项递推

双正交化方法的关键公式是

$$AV_n = V_{n+1}\widetilde{T}_n, \tag{39.8}$$

$$A^* W_n = W_{n+1}\widetilde{S}_n, \tag{39.9}$$

$$T_n = S_n^* = W_n^* A V_n. \tag{39.10}$$

这里 $V_n$ 和 $W_n$ 的大小为 $m \times n$；$\widetilde{T}_n$ 和 $\widetilde{S}_n$ 是大小为 $(n+1) \times n$ 的（非 Hermitian）三对角矩阵。$T_n = S_n^*$ 是 $n \times n$ 矩阵：从 $\widetilde{T}_n$ 删除最后一行，或从 $\widetilde{S}_n^*$ 删除最后一列，就得到它。

与第 33 讲和第 36 讲的推导类似，式（39.8）对应的三项递推为

$$Av_n = \gamma_{n-1} v_{n-1} + \alpha_n v_n + \beta_n v_{n+1}. \tag{39.11}$$

相应地，式（39.9）为

$$A^* w_n = \overline{\beta}_{n-1} w_{n-1} + \overline{\alpha}_n w_n + \overline{\gamma}_n w_{n+1}. \tag{39.12}$$

这里出现复共轭符号，是因为本讲不再像前面三讲那样假设 $A$ 为实矩阵。

这两个递推自然给出一个算法。首先取 $v_1, w_1$ 为任意满足 $w_1^* v_1 = 1$ 的向量，并令

$$\beta_0 = \gamma_0 = 0, \qquad v_0 = w_0 = 0.$$

对 $n = 1, 2, \ldots$，根据式（39.6）和式（39.11）或式（39.12）设置

$$\alpha_n = w_n^* A v_n.$$

然后由式 (39.11) 和式 (39.12) 确定 $v_{n+1}$、$w_{n+1}$，它们各自只确定到一个标量因子。这个因子可以任意选择，但要满足归一化条件 $w_{n+1}^* v_{n+1} = 1$；确定了这个归一化之后，$\beta_{n+1}$ 和 $\gamma_{n+1}$ 就由两个递推关系确定。

上述过程生成的向量属于两个 Krylov 子空间：

$$\begin{aligned} v_n &\in \operatorname{span}\{v_1, Av_1, \ldots, A^{n-1}v_1\}, \\ w_n &\in \operatorname{span}\{w_1, A^*w_1, \ldots, (A^*)^{n-1}w_1\}. \end{aligned} \tag{39.13}$$

对于一般矩阵，在精确算术下，过程会在 $m$ 步后完成。但对某些特殊矩阵，过程可能提前崩溃。如果某一步出现 $v_n = 0$ 或 $w_n = 0$，说明已经找到 $A$ 或 $A^*$ 的不变子空间；此时三对角矩阵 $T$ 是可约的。另一种情况是 $v_n \neq 0$、$w_n \neq 0$，但

$$w_n^* v_n = 0.$$

这是更严重的双正交化崩溃，几乎所有双正交化方法都可能遇到。和数值分析的其他领域一样，某些问题上精确崩溃是可能的，意味着更多问题上会出现近崩溃；在浮点算术中，这可能带来不利后果。处理这些现象的一些方法会在本讲结尾提到。

# BCG：双共轭梯度法

上述双正交化过程的一种用途是计算特征值：当 $n \to \infty$ 时，$T_n$ 的某些特征值可能快速收敛到 $A$ 的某些特征值。另一种用途是求解非奇异线性系统 $Ax = b$；本节简要介绍的经典算法称为双共轭梯度法（biconjugate gradients，BCG）。

BCG 的基本思想如下。取 $v_1 = b$，于是式（39.13）中的第一个 Krylov 子空间变成

$$\mathcal{K}_n = \operatorname{span}\{b, Ab, \ldots, A^{n-1}b\}.$$

回顾 GMRES：它从 $\mathcal{K}_n$ 中选择 $x_n$，使正交条件

$$\text{GMRES:} \qquad r_n \perp \operatorname{span}\{Ab, A^2b, \ldots, A^n b\} = A\mathcal{K}_n \tag{39.14}$$

成立，其中 $r_n = b - Ax_n$ 是对应于 $x_n$ 的残量（见图 35.1）。这一选择使残量 $\|r_n\|_2$ 最小。BCG 则仍然从同一个子空间中选择 $x_n \in \mathcal{K}_n$，但强制满足另一组正交条件：

$$\text{BCG:} \qquad r_n \perp \operatorname{span}\{w_1, A^*w_1, \ldots, (A^*)^{n-1}w_1\}. \tag{39.15}$$

这里 $w_1 \in \mathbb{C}^m$ 是任意满足 $w_1^* v_1 = 1$ 的向量；实际应用中有时取

$$w_1 = \frac{v_1}{\|v_1\|_2^2}.$$

与式（39.14）不同，这个选择不保证最小化 $\|r_n\|_2$，从减少迭代次数的角度看也不是最优的。它的优势在于：可以使用三项递推实现，而不必使用 GMRES 的 $(n+1)$ 项递推。

## 算法 39.1：BCG 迭代

下面不给出推导，只记录 BCG 的标准形式。应当把它和算法 38.1 的 CG 迭代进行对照：CG 的搜索方向序列 $\{p_n\}$ 变成两组序列 $\{p_n\}$ 和 $\{q_n\}$，残量序列 $\{r_n\}$ 变成两组序列 $\{r_n\}$ 和 $\{s_n\}$。

**算法 39.1　双共轭梯度（BCG）迭代**

$$x_0 = 0, \qquad p_0 = r_0 = b, \qquad q_0 = s_0 = \text{任意向量}.$$

对 $n = 1, 2, 3, \ldots$：

$$\begin{aligned}
\alpha_n &= \frac{s_{n-1}^* r_{n-1}}{q_{n-1}^* A p_{n-1}}, \\
x_n &= x_{n-1} + \alpha_n p_{n-1}, \\
r_n &= r_{n-1} - \alpha_n A p_{n-1}, \\
s_n &= s_{n-1} - \alpha_n A^* q_{n-1}, \\
\beta_n &= \frac{s_n^* r_n}{s_{n-1}^* r_{n-1}}, \\
p_n &= r_n + \beta_n p_{n-1}, \\
q_n &= s_n + \beta_n q_{n-1}.
\end{aligned}$$

和定理 38.1 一样，可以直接验证，对 $j < n$ 有

$$s_n^* r_j = 0, \qquad q_n^* A p_j = 0.$$

# 例

图 38.1 说明了一个由参数 $\tau$ 控制的 $500 \times 500$ 稀疏对称正定矩阵上 CG 迭代的收敛。现在对同一个矩阵只做一处修改：随机改变全部元素的符号。这样得到的矩阵不再是 Hermitian 的；对角线上原本全为 1 的主导元素现在随机取 1 或 $-1$，所以特征值聚集在 1 和 $-1$ 附近，而不再只聚集在 1 附近。

图 39.2 展示了 $\tau = 0.01$ 时 GMRES 与 BCG 的收敛。先看 GMRES 曲线：与图 38.1 相比，收敛速度约慢了一半；奇数步几乎没有进展，而偶数步保持稳定下降。这种奇偶步

效应来自矩阵近似的 $\pm 1$ 对称性：若多项式 $p(z)$ 的次数为 $2k+1$ 且 $p(0)=1$，那么它在 1 和 $-1$ 处不可能同时小于某个相应的 $2k$ 次多项式。

再看 BCG 曲线：从总体趋势看，其收敛速度相当，但不再单调，并且在每个奇数步附近出现幅度最高约为 $10^2$ 的尖峰。最终达到的精度也比 GMRES 少了一位以上。这些都是 BCG 计算中常见的现象。

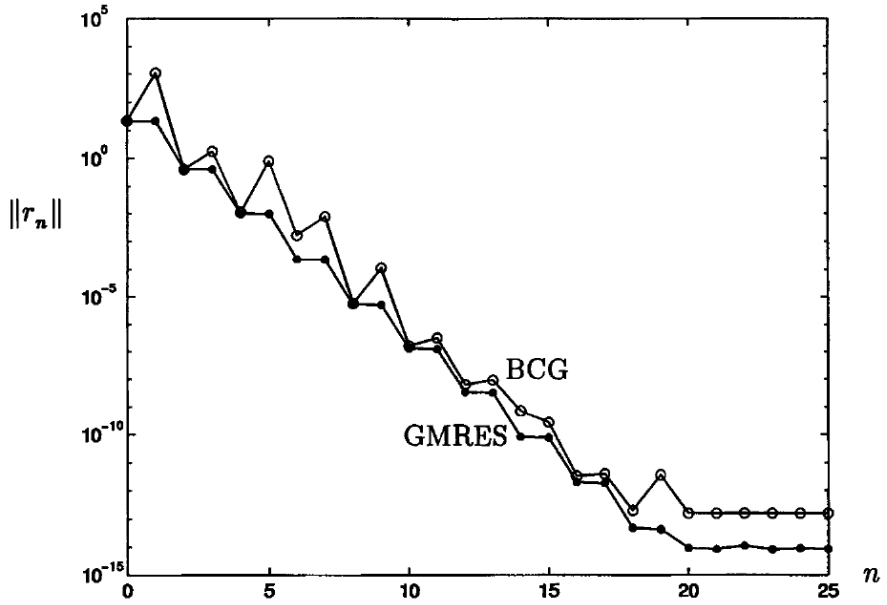



图 39.2. 对图 38.1 中标记为 $\tau = 0.01$ 的 $500\times500$ 矩阵随机改变所有元素符号后，GMRES 与 BCG 的比较。图中曲线和坐标标注保留源图形式；正文给出中文解读。

图 39.2 的横轴是迭代步数 $n$，它不等于计算代价。每一步 GMRES 需要一次涉及 $A$ 的矩阵–向量乘法，而 BCG 需要分别涉及 $A$ 和 $A^*$ 的乘法。若矩阵–向量乘法占主要开销且存储空间足够，GMRES 可能因此比 BCG 快一倍甚至更多。不过在本例中，矩阵足够稀疏，长递推关系的维护开销已经不可忽略；事实上，图 39.2 中 BCG 的计算速度比 GMRES 快两倍以上。

## QMR 及其他变体

BCG 相对于 GMRES 的一个重要优点是使用三项递推：即使需要很多步，每一步的工作量和存储需求也能保持在可控范围内。但它有两个缺点。

第一，与 GMRES 随步数通常单调且常常很快的收敛相比，BCG 收敛更慢、也更不规则，有时会比图 39.2 中显示的情况不规则得多。不规则收敛本身就不理想，而且舍入误差可能使最终可达到的精度降低（见习题 39.4）。极端情况下会发生迭代崩溃：某个内积变成零，之后无法继续取得进展，即使原线性系统本身是条件良好的。

第二，BCG 既需要乘以 $A$，也需要乘以 $A^*$。这些乘法在数学上以及计算机体系结构上的实现方式不同，因此额外负担可能从很小到几乎无法承担不等。

针对这两个问题，自 20 世纪 80 年代起，人们提出了十多种 BCG 变体。下面列出几种最著名的方法，相关参考文献见本书注释：

- 前视 Lanczos（Look-ahead Lanczos，Parlett、Taylor 和 Liu，1985）；
- CGS，即共轭梯度平方（conjugate gradients squared，Sonneveld，1989）；
- QMR，即拟最小残量（quasi-minimal residuals，Freund 和 Nachtigal，1991）；
- Bi-CGSTAB，即稳定化 BCG（van der Vorst，1992）；
- TFQMR，即无转置 QMR（transpose-free QMR，Freund，1993）。

这里只作简要说明，不给出细节。

**前视 Lanczos。** 当迭代即将崩溃时，不一次只走一步，而是一次走两步或更多步，就可能避免崩溃。Parlett 等人提出的原始想法后来得到广泛发展，例如被纳入 QMR 作者推荐的算法版本。可以证明，崩溃现象等价于某个函数的 Padé 逼近表中出现相同元素组成的方块；前视思想就是一次跨过这些方块。实际计算中不会只检测精确崩溃，还要用适当容差定义“近崩溃”。

**CGS。** 如果把 BCG 的两步以另一种方式合并为一步，使算法被“平方化”，就可以避免乘以 $A^*$。结果是一个“无转置”方法，有时收敛速度最多可达 BCG 的两倍，但收敛的不规则程度也可能约为两倍。

**QMR、Bi-CGSTAB 与 TFQMR。** 三项递推不能用来最小化 $\|r_n\|_2$，但可以用来最小化另一种依赖数据的范数；实际中，这个范数通常不会和 $\|r_n\|_2$ 相差太远。这可能显著改善收敛曲线的平滑性，并降低舍入误差的影响。Bi-CGSTAB 也会显著平滑 BCG 的收敛速度；TFQMR 则是 QMR 的一个变体，在保持平滑收敛的同时避免了对 $A^*$ 的需求。

最近的工作试图把三种优点结合到一起：平滑的收敛曲线、用于避免崩溃的前视机制，以及无转置运算。到目前为止，三者还没有在一个算法中得到完全令人满意的结合；这个研究方向仍然很年轻。

# 习题

**39.1.** 考虑矩阵（39.5）给出的 $m$ 维问题 $Ax = b$。

(a) 证明所有奇异值都等于 1，并说明这为什么意味着 CGN 一步收敛。

(b) 证明所有特征值都是 $m$ 次单位根，并说明这为什么意味着对一般的 $b$，GMRES 需要 $m$ 步才能收敛。

(c) 这个矩阵具有很强的结构，不需要借助特征值或奇异值也能理解其收敛行为。特别地，对右端项 $b = (1, 0, 0, \ldots, 0)^T$，用初等论证解释为什么 GMRES 需要 $m$ 步才能收敛。

**39.2.** 构造一个任意维数 $m$ 的矩阵，具有与习题 39.1 几乎相反的性质：GMRES 两步收敛，而 CGN 需要 $m$ 步。

**39.3.**

(a) 若 $A$ 是 Hermitian 矩阵，并适当地选择 $s_0$，算法 39.1 会退化为算法 38.1。验证这一说法，并确定合适的 $s_0$。

(b) 设 $A$ 是复矩阵，且对称但不是 Hermitian。证明选择另一个 $s_0$ 后，算法 39.1 仍可退化为只包含一个三项递推的迭代。

**39.4.** 图 39.2 表明，如果双正交化方法的收敛曲线含有尖峰，那么它可能影响浮点算术中最终可达到的精度。不必追求严格证明，解释为什么会这样，并评论它与高斯消去中增长因子（第 22 讲）的类比。

**39.5.** 对于下面的 $m \times m$ 问题 $Ax = b$，你认为 CG、GMRES、CGN、BCG 中哪一个最有效？说明理由。

(a) 稠密的非 Hermitian 矩阵，$m = 10^4$，除三个特征值外，其余特征值都近似等于 $-1$。

(b) 与（a）相同，但除三个特征值外，其余特征值散布在区域 $-10 \le \mathrm{Re}(\lambda) \le 10$、$-1 \le \mathrm{Im}(\lambda) \le 1$。

(c) 稀疏的非 Hermitian 矩阵，$m = 10^6$，但只有 $10^7$ 个非零元；特征值如（a）。

(d) 稀疏的 Hermitian 矩阵，$m = 10^5$，特征值散布在区间 $[1, 100]$。

(e) 与（d）相同，但有两个离群特征值 0.01 和 10000。

(f) 与（d）相同，但另外还有离群特征值 $-1$、$-10$ 和 $-100$。

(g) 稀疏的正规矩阵，$m = 10^5$，特征值是复数，散布在环域 $1 \le |\lambda| \le 2$ 内。